Actividad 1- *From reads to gene counts*

Objetivo

El propósito de esta actividad es que el estudiante demuestre que ha adquirido las habilidades y competencias necesarias para realizar el **preprocesamiento inicial de datos de ARN-seq.** Esto incluye desde la caracterización y evaluación de calidad de las lecturas crudas hasta su filtrado, alineación y generación de la matriz final de recuentos génicos.

Obtención de los datos

La actividad consiste en el análisis de una muestra real de ARN-seq, que forma parte de un estudio más amplio sobre los perfiles de expresión entre poblaciones de células basales y luminales en glándulas mamarias de ratones en diferentes estadios (vírgenes, gestantes y lactantes).

Referencia al estudio:

Fu, Nai Yang, et al. "EGF-mediated induction of Mcl-1 at the switch to lactation is essential for alveolar cell survival." *Nature Cell Biology* 17.4 (2015): 365-375.

Todo el material necesario para realizar esta actividad ha sido previamente explicado en clase. Esto incluye el entorno de trabajo **conda 05MBIF** y los archivos requeridos, los cuales están disponibles en la sección **"Recursos y Materiales > Materiales del profesor > Proyecto_JULIO_2025"**.

Formato de la entrega

- La entrega se realizará utilizando este documento como plantilla, convertido a **PDF** y adjuntado en la actividad correspondiente dentro del Campus VIU.
- Las respuestas deben ser claras, concisas y justificadas, añadiendo siempre la captura de pantalla que lo demuestre.
- El idioma de entrega será siempre el español.
- Deben emplearse las mismas versiones de las herramientas utilizadas en clase.
- Añadir referencias bibliográficas cuando sea necesario para dar consistencia a tus afirmaciones.
- Se deberá adicionar **SIEMPRE** los comandos empleados, las capturas de pantalla que evidencien su ejecución y los gráficos generados que apoyen cada repuesta:
    - Añadir las evidencias en cada pregunta, y no de forma global al final del documento.
    - Para salidas estándar extensas, incluir solo las primeras líneas que muestren su ejecución.
    - No es necesario explicar con detalle los comandos, opciones o argumentos empleados.
    - No se deben incluir pasos de instalación, creación de directorios ni de generación de entornos.
- **Gráficos:** deben tener calidad suficiente para su correcta lectura y estar acompañados de un **pie de figura explicativo** con su numeración (Ejemplo: *Figura X: "..."*).

Preguntas

Para alcanzar la nota máxima, se deberán contestar y justificar cada una de las siguientes preguntas.

P1. Responde brevemente a las siguientes preguntas, consultando el artículo de referencia: (1 pts)

1. ¿Cuántos nanogramos de ARN total se utilizaron para la preparación de bibliotecas?
2. ¿Qué protocolo específico se empleó para la preparación de las bibliotecas de ARN-seq?
3. ¿Qué plataforma de secuenciación se utilizó en este estudio?
4. ¿Cuál fue la longitud de las lecturas obtenidas y cuántas lecturas mínimas se generaron por muestra?

Para contestar esta pregunta se seleccionó la información del apartado "Methods" del artículo de referencia.

1. El RNA total que se usó para la preparación de bibliotecas para el análisis transcriptómico fue **100 ng.**
2. El protocolo de preparación de muestras que se utilizó fue el específico de **Illumina TruSeq RNA v2.**
3. Las librerías fueron secuenciadas en un **Illumina HiSeq 2000 en la Australian Genome Research Facility (AGRF) en Melbourne.**
4. Se obtuvieron al menos **20 millones de lecturas de 100 pares de bases single-end por cada muestra.**

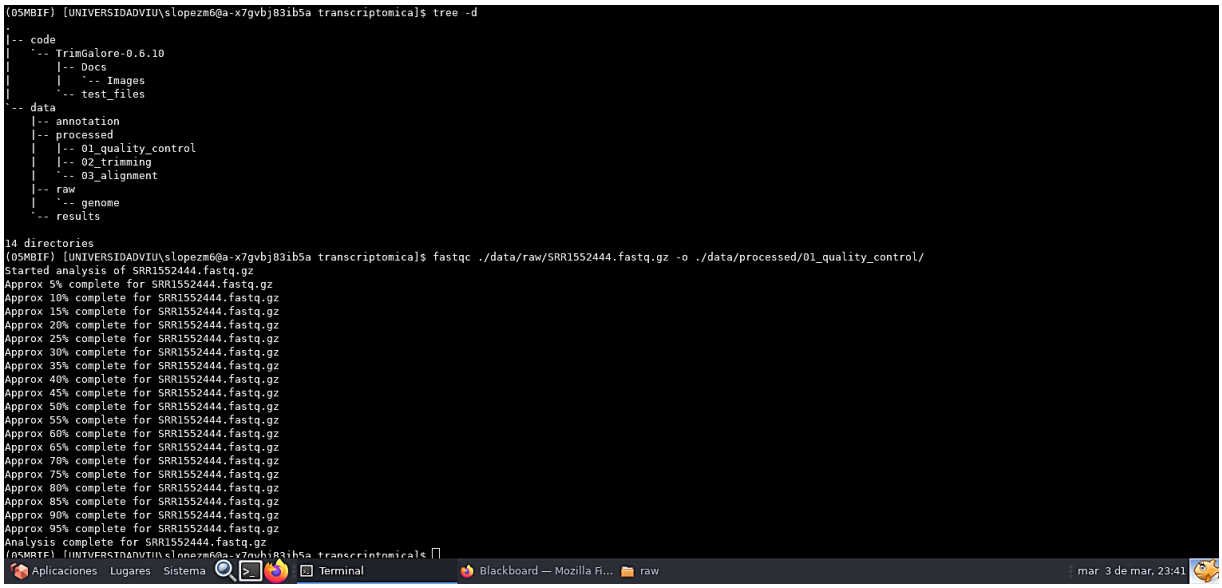
RNA-seq analysis. Total RNA was extracted from sorted luminal or basal populations from the mammary glands of virgin, 18.5-day-pregnant and 2-day-lactating FVB/N female mice (two independent samples per stage). Total RNA (100 ng) was used to generate libraries for whole-transcriptome analysis following Illumina's TruSeq RNA v2 sample preparation protocol. Libraries were sequenced on an Illumina HiSeq 2000 at the Australian Genome Research Facility (AGRF), Melbourne. At least 20 million 100 bp single-end reads were obtained for each sample. Reads were aligned to the mouse genome mm10 using Rsubread version 13.25 (ref. 51). The number of reads overlapping each Entrez gene was counted using RefSeq gene annotation and featureCounts[51]. Filtering and normalization used the edgeR package[52]. Genes were filtered as unexpressed if their average count per million (CPM) computed by the aveLogCPM function was less than one. Compositional differences between libraries were normalized using the trimmed mean of *M*-values (TMM) method[53]. Differential expression was analysed used the Limma package[54]. Counts were transformed to $\log_2$-CPM values with associated precision weights using voom[55]. Differential expression was assessed using the TREAT method[56], whereby differential expression is evaluated relative to a biologically meaningful

Texto 1: RNA-seq análisis del apartado "Methods" del artículo de referencia

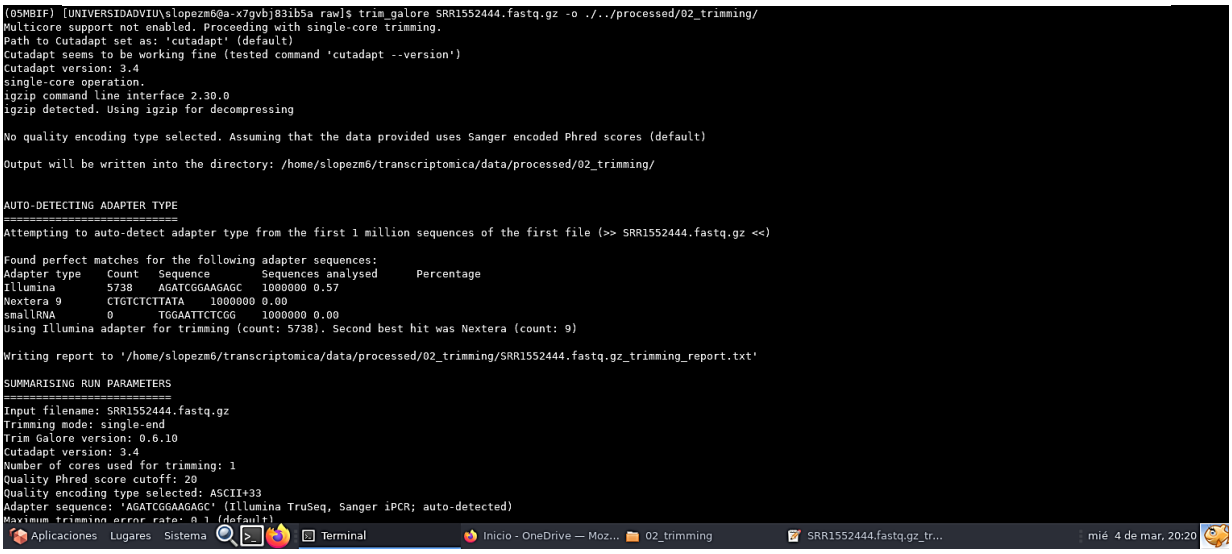
P2. Emplea la herramienta FastQC para evaluar la calidad de las lecturas del archivo SRR1552444.fastq.gz. A continuación, utiliza la herramienta TrimGalore para eliminar adaptadores y extremos de baja calidad con los parámetros por defecto. Reporta los comandos utilizados y responde a las siguientes preguntas (2,5 pts).

- ¿Cuántas lecturas contiene el archivo original SRR1552444.fastq.gz y cuántas permanecen tras la utilización de TrimGalore?
- Empleando el informe FastQC generado antes y después del filtrado. Responde a las siguientes preguntas:
    - **Per base sequence quality**
        - ¿A partir de qué bases específicamente se observa una mejora en la calidad por base?

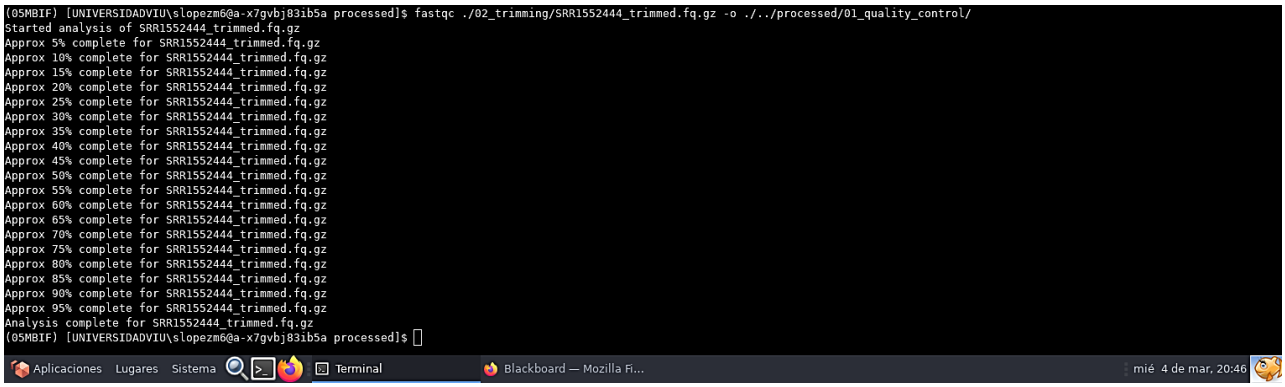
- Sequence Length Distribution
  - ¿Cual es el tamaño medio de lecturas tras aplicar TrimGalore?
- Adapter Content (no haria falta poner los gráficos)
  - ¿Qué secuencia se identificado como el adaptador principal? ¿En cuántas lecturas ha detectado dicho adaptador TrimGalore?



Captura de pantalla 1: Primero, se emplea *FastQC* sobre el archivo SRR1552444.fastq.gz sin descomprimir (ubicado en "raw"); el resultado del análisis se redirige a Quality Control (ubicado en "processed").



Captura de pantalla 2: Se utiliza *TrimGalore* para eliminar adaptadores y extremos de baja calidad, y el output se redirige a 02_trimming para su organización, y se hace nuevamente un *FastQC* en el archivo resultante tras el filtrado.



Captura de pantalla 3: Tras realizar el *FastQC* del archivo filtrado, se comparan los resultados para contestar a las preguntas de este ejercicio.

- El **archivo original** SRR1552444.fastq.gz contiene **27919481 lecturas (Tabla1)**; tras la utilización de *TrimGalore* **quedan 27906762 lecturas (Tabla 2).** Las 12719 lecturas de diferencia entre el archivo original y el archivo filtrado son aquellas que quedaron por debajo del "límite", es decir, las que después de recortar quedaron muy cortas (normalmente el límite está en menos de 20 pb) y, de incluirse en el análisis final, podría causar problemas en el alineamiento o generar "ruido" sin aportar información significativa.[1]

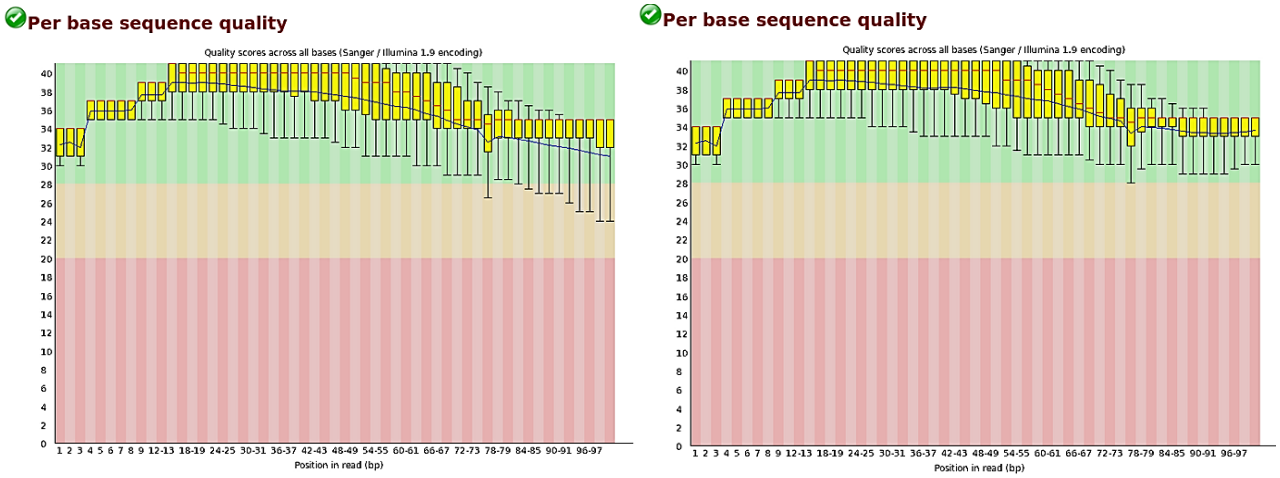
- La calidad por base tras la utilización de *TrimGalore* mejora significativamente en el extremo 3' de las lecturas, específicamente **a partir de la base 78-79 en adelante (Gráfica 1 y 2).**

Measure	Value
Filename	SRR1552444.fastq.gz
File type	Conventional base calls
Encoding	Sanger / Illumina 1.9
Total Sequences	27919481
Sequences flagged as poor quality	0
Sequence length	100
%GC	49

Tabla 1: *Basic Statistics* del archivo original

Measure	Value
Filename	SRR1552444_trimmed.fq.gz
File type	Conventional base calls
Encoding	Sanger / Illumina 1.9
Total Sequences	27906762
Sequences flagged as poor quality	0
Sequence length	20-100
%GC	49

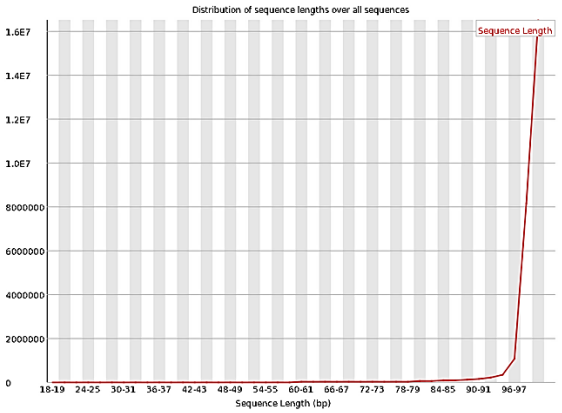
Tabla 2: *Basic Statistics* del archivo tras la utilización de *TrimGalore*



Gráfica 1 (izquierda) y gráfica 2 (derecha): *Per base sequence quality* del archivo antes y después de la utilización de *TrimGalore*.

[1] Barbraham_Bioinformatics. Taking appropriate QC measures for RRBS-type or other -seq applications with Trim Galore!. GitHub. [citado el 4 de marzo de 2026]. Disponible en: https://github.com/FelixKrueger/TrimGalore/blob/master/Docs/Trim_Galore_User_Guide.md#step-1-quality-trimming

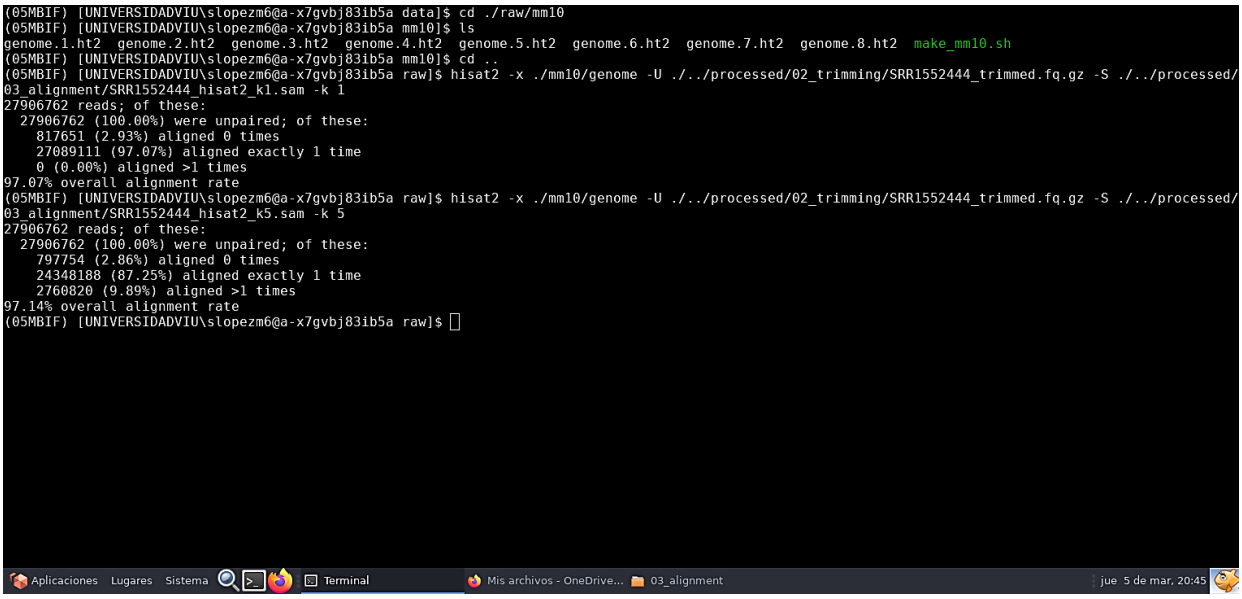
- El tamaño medio de lecturas tras aplicar *TrimGalore* es de **entre 20-100 pb** (siendo 20 pb aproximadamente el límite inferior de longitud por el cual se aceptan o se descartan las lecturas recortadas como comentaba anteriormente hablando del número total de secuencias), ya que en el extremo 3´ hay algunas lecturas que han sido recortadas y mantienen un tamaño variable, pero la gran mayoría se siguen manteniendo en 100 pb o próximo a ello, como se ve en el pico del gráfico (Gráfica 3). El tamaño medio también aparece reflejado en *Basic Statistics – Sequence Lenght* (Tabla 2).



Gráfica 3: *Sequence Length Distribution* del después de la utilización de *TrimGalore*.

- El **adaptador principal identificado es el de Illumina TruSeq** con la secuencia **AGATCGGAAGAGC** tal y como se puede comprobar en el informe de *TrimGalore*; y se ha **detectado y eliminado este adaptador en 9664562 lecturas** (lo que supone un **34.6% del total** de las secuencias procesadas).

P3. Alinea las lecturas depuradas anteriormente sobre el genoma de referencia indexado empleando la herramienta Hisat2 con la opción (-k = 1). Reporta los comandos empleados y contesta a las siguientes preguntas. (1,5 pts)



Captura de pantalla 4: Se emplea la herramienta HISAT2 con la opción -k 1 y -k 5 para contestar las cuestiones. Se aplican los criterios de organización de archivos que proceden en este caso.

- Después del alineamiento con Hisat2, ¿cuál fue el número total de lecturas mapeadas con éxito y cuántas quedaron sin mapear?

  Las lecturas que fueron alineadas con éxito (1 vez exactamente ya que se indicó -k=1) son **27089111 (un 97.07%** de las lecturas). Quedaron **sin mapear 817651 lecturas** (un 2.93%).

- Uno de los parámetros clave de Hisat2 es -k, que define el número máximo de alineamientos por lectura.
  - ¿Cómo afecta el uso de **-k 5** en comparación con **-k 1** en los valores finales de alineamiento?

  El parámetro -k 5 permite a HISAT2 reportar hasta 5 posibles sitios de alineamiento para una misma lectura, y al usarlo observamos que 2760820 lecturas (un 9.89%) se clasifican como alineadas más de 1 vez (>1 times), y 24348188 lecturas (un 87.25%) se alinean exactamente 1 vez, cuando en -k 1 el número de lecturas alineadas exactamente una vez era del 27089111 (97.07%) por la configuración que pusimos, pero eso no quiere decir que todas ellas solo se alineasen una vez en la realidad. Por lo tanto, la consecuencia directa de usar -k 5 es que el número de lecturas que se alinean una vez exactamente disminuye, ya que muchas lecturas en -k 1 se forzaban a reportar un único alineamiento cuando en realidad podían encajar en varios, especialmente teniendo en cuenta la presencia de genes parálogos que estén en el genoma de *Mus musculus* y que, al ser tan parecidos entre ellos, puedan encajar en el alineamiento.

  - ¿Cómo influye el valor de **-k 5** en el tiempo de ejecución y en el tamaño del archivo final?

  El uso de -k 5 afecta drásticamente al **tiempo de ejecución (tarda mucho más en terminar el alineamiento)** porque el algoritmo tiene que explorar muchas más posibilidades en lugar de detenerse en el primer alineamiento de buena calidad como ocurría con -k 1.
  También **afecta al tamaño del archivo final, siendo el tamaño del archivo -k 1 menor que el del archivo -k 5 (8.9 GB vs 10.6 GB respectivamente);** esto se debe a que el formato SAM dedica una fila por cada alineamiento[2], y si una lectura mapea en 5 sitios distintos, el programa escribirá 5 líneas enteras para esa misma lectura, lo cual aumenta el peso final del archivo.

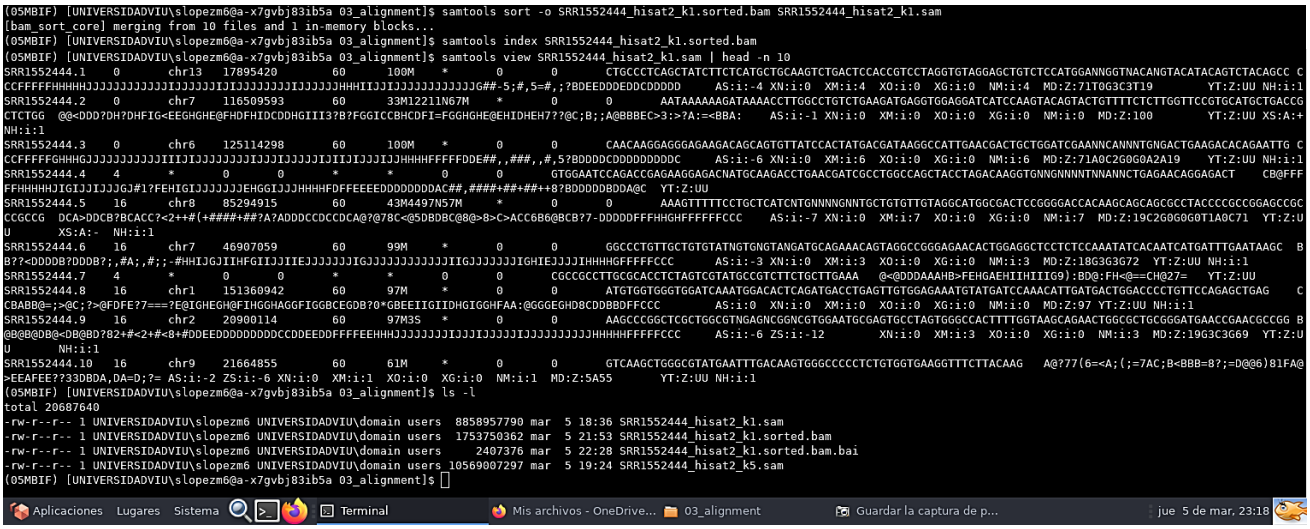
  - Basado en los resultados obtenidos, ¿cuál de los dos valores considerarías más adecuado y por qué?

  A pesar de lo que pudiera parecer, que -k 5 sea capaz de alinear las lecturas en más lugares, no lo hace necesariamente mejor. De hecho, a la hora de realizar un análisis transcriptómico, una lectura que mapea en múltiples genes distintos genera ambigüedad estadística y esto puede darnos problemas después a la hora de utilizar otras herramientas como *htseq-count* ya que, al aparecer cuantificada varias veces, puede dar error. **Usar -k 1 es más adecuado para este tipo de procedimientos** porque **simplifica el archivo final**, lo cual conviene a la hora de ahorrar espacio (genera archivos menos pesados, y el almacenamiento es caro, por lo que es un factor

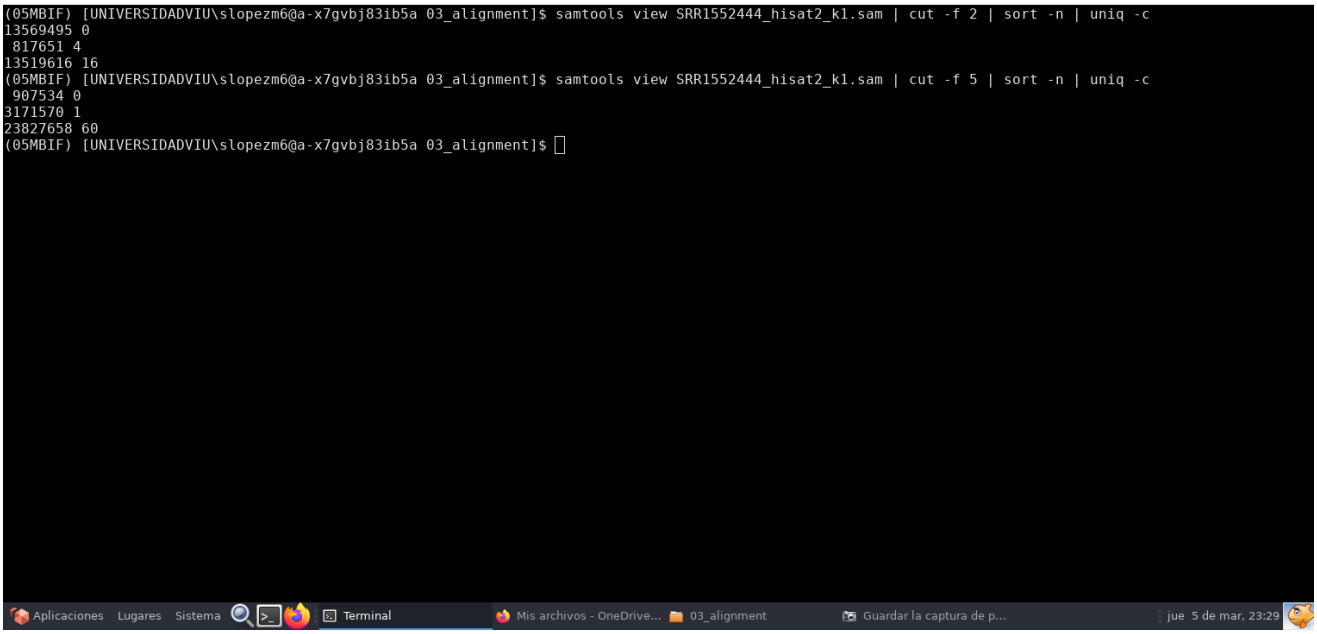
[2] HISAT2 manual [citado el 5 de marzo de 2026]. Disponible en: https://daehwankimlab.github.io/hisat2/manual/

importante que valorar), **ahorra mucho tiempo** (el análisis de -k 5 tarda muchísimo más), y **facilita los siguientes pasos del análisis transcriptómico**.

P4. Utiliza SAMtools para convertir el archivo SAM (generado con el valor de -k igual a 1) a BAM, ordenarlo por coordenadas e indexarlo. Reporta los comandos utilizados y contesta a las siguientes preguntas. (1 pts)



Captura de pantalla 5: se utiliza *SAMtools* para convertir el archivo *SAM* a *BAM*, para esto primero se ordena el archivo en el que -k = 1, y el output del archivo ordenado pasa de *.sam* a *.bam* y posteriormente se indexa, dando lugar a un archivo *.bam.bai.*



Captura de pantalla 6: para determinar cuantas *FLAGS* distintas y cuantos valores de *MAPQ* distintos hay se hace un *view* del archivo *SAM* -k 1 y se escogen las columnas que corresponden a las *FLAGS* (columna 2) y al *MAPQ* (columna 5), se ordenan y se cuentan las coincidencias, dando lugar al resultado de los siguientes apartados.

- ¿Cuántas FLAGs distintas se encuentran en el archivo **SRR1552444_hisat2.sam**? Indica cuáles son y sus cantidades.

  Se encuentran **3 FLAGs distintas (captura de pantalla 6)**:

  1. **FLAG 0**: Aparece en 13569495 alineamientos. Indica que la lectura mapea en la cadena forward del genoma de *Mus musculus*.
  2. **FLAG 4**: Aparece en 817651 lecturas. Indica que la secuencia se encuentra no fue mapeada. Este valor es el mismo que indicaba anteriormente HISAT2 en su análisis.
  3. **FLAG 16**: Aparece en 13519616 alineamientos. Indica que la lectura mapea en la cadena reverse del genoma de *Mus musculus*.

- ¿Cuántos valores distintos de MAPQ hay en el archivo **SRR1552444_hisat2.sam**? Indícalos y cuenta cuántos son.

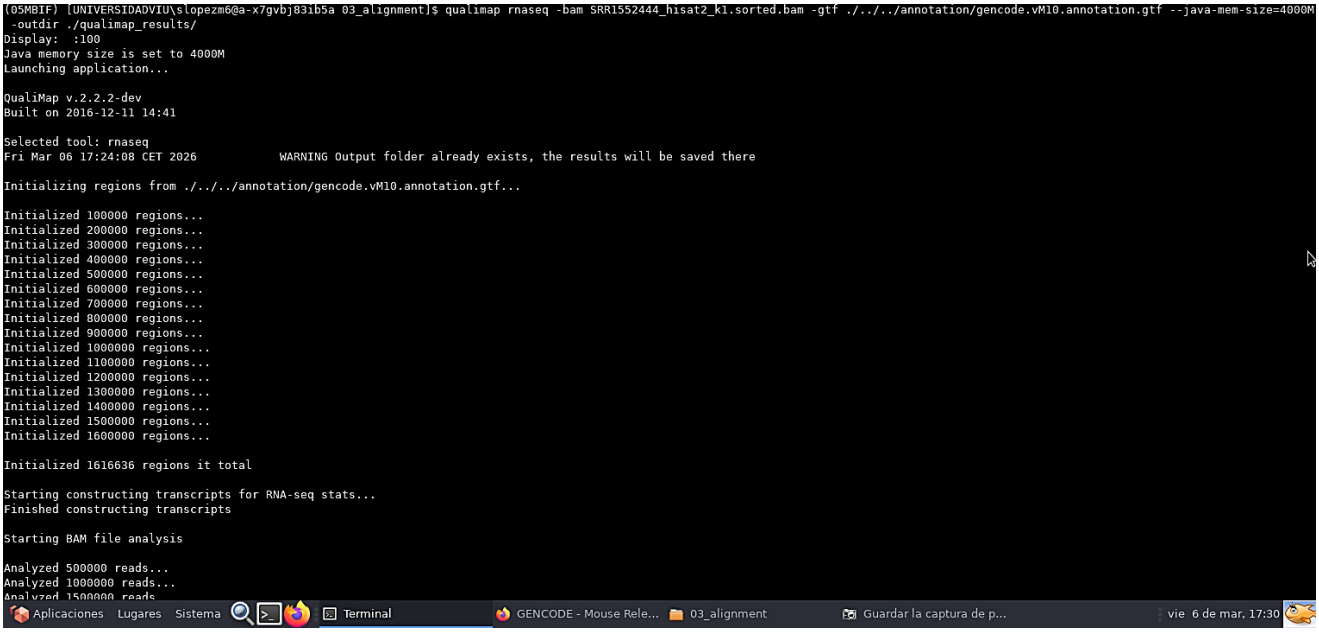
  Se encuentran **3 valores distintos de MAPQ (captura de pantalla 6)**:

  1. **MAPQ 0:** Presente en 907534 lecturas. Corresponde a las lecturas marcadas con FLAG 4 (las no mapeadas) + aquellas cuyos resultados son tan ambiguos que estadísticamente el programa no puede asegurar el "acierto", por lo que su valor de calidad es el mismo que si no se hubiera mapeado.
  2. **MAPQ 1**: Presente en 3171570 lecturas. Indica un alineamiento de calidad muy baja, el programa "duda" de que sea correcto el alineamiento.
  3. **MAPQ 60:** Presente en 23827658 lecturas. Indica la máxima puntuación de calidad que se puede conseguir, la gran mayoría de las secuencias han mapeado de forma única y con un buen nivel de confianza en el genoma de *Mus musculus*.

P5. Utiliza QualiMap para evaluar la calidad del alineamiento. Para ello, deberás instalar la herramienta en nuestro entorno de trabajo (*conda install bioconda::qualimap*). Luego, ejecútala utilizando la siguiente instrucción:

qualimap rnaseq --bam SRR1552444_hisat2.sorted.bam -gtf ../../Annotation/gencode.vM10.annotation.gtf --java-mem-size=4000M -outdir ../../../Results/rnaseq_qc_results

Responde a las siguientes preguntas basándote en los resultados obtenidos **(1 pts)**.



Captura de pantalla 7: se ejecuta la instrucción del enunciado, modificando el output para que concuerde con el sistema de organización utilizado.

1. **Distribución de lecturas en el genoma (Reads Genomic Origin):**
   - ¿Existe un predominio de lecturas en algún tipo de región? ¿Es esperable según el diseño del experimento?

   Sí, **existe un predominio en regiones exónicas**, que ocupan un 84.74% de las lecturas, frente a un 10.38% en regiones intrónicas y solo un 4.88% en regiones intergénicas (Tabla 3).
   Es esperable y de hecho es lo deseado en un experimento de ARN-seq, ya que la durante la transcripción y la maduración del ARN, los intrones son eliminados y los exones se empalman (splicing)[3], y dado que estamos leyendo ARN maduro, la inmensa mayoría de las secuencias tienen que corresponder a exones codificantes, si no fuera así habría que sospechar que el ARN está contaminado.

Reads genomic origin

Exonic:	22.362.773 / 84,74%
Intronic:	2.739.252 / 10,38%
Intergenic:	1.288.413 / 4,88%
Intronic/intergenic overlapping exon:	1.157.376 / 4,39%
Exonic inside rRNA:	0 / 0%

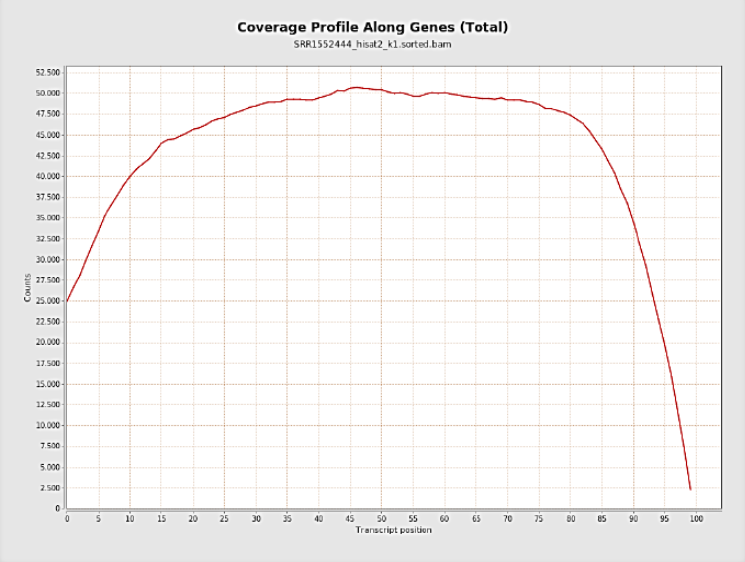
Tabla 3: *Reads genomic origin* del alineamiento tras la utilización de *Qualimap*

[3] CD-Genomics. Fact Sheet: Introns and Exons. [citado el 6 de marzo de 2026]. Disponible en: https://www.cd-genomics.com/blog/introns-and-exons/

2. **Perfil de cobertura de los transcriptos (Transcript Coverage Profile):**
    - ¿Se observa algún sesgo sistemático en la cobertura, como una mayor acumulación en los **extremos 5’ o 3’**? ¿Es esperable según el tipo de experimento?

En el “Transcript coverage profile” (Tabla 4) se puede ver que **hay un sesgo mayor hacia el extremo 5´ en comparación con el 3´** pero no es pronunciado. De hecho, el sesgo 5´-3´ es de 1.23 en este caso, y en un experimento “perfecto” lo ideal es que haya un sesgo 5´-3´ de 1, que significaría que no hay acumulación en ningún extremo concreto[4], por lo que el sesgo existe, pero no se desvía tanto de lo “ideal”.

Si es esperable y concuerda con el diseño de un experimento RNA-seq estándar con el protocolo de Illumina[5] TruSeq RNA v2. La disminución de las lecturas en los extremos es un artefacto normal, ya que estadísticamente es menos probable que los cebadores utilizados para la retrotranscripción hibriden exactamente en los bordes de los fragmentos, es más “fácil” que hibriden en el centro, por eso la gráfica es una meseta pronunciada que cae en los extremos exactos.



Gráfica 4: *Coverage Profile Along Genes (total)* del alineamiento tras la utilización de *Qualimap*

Transcript coverage profile

5' bias:	0,75
3' bias:	0,53
5'-3' bias:	1,23

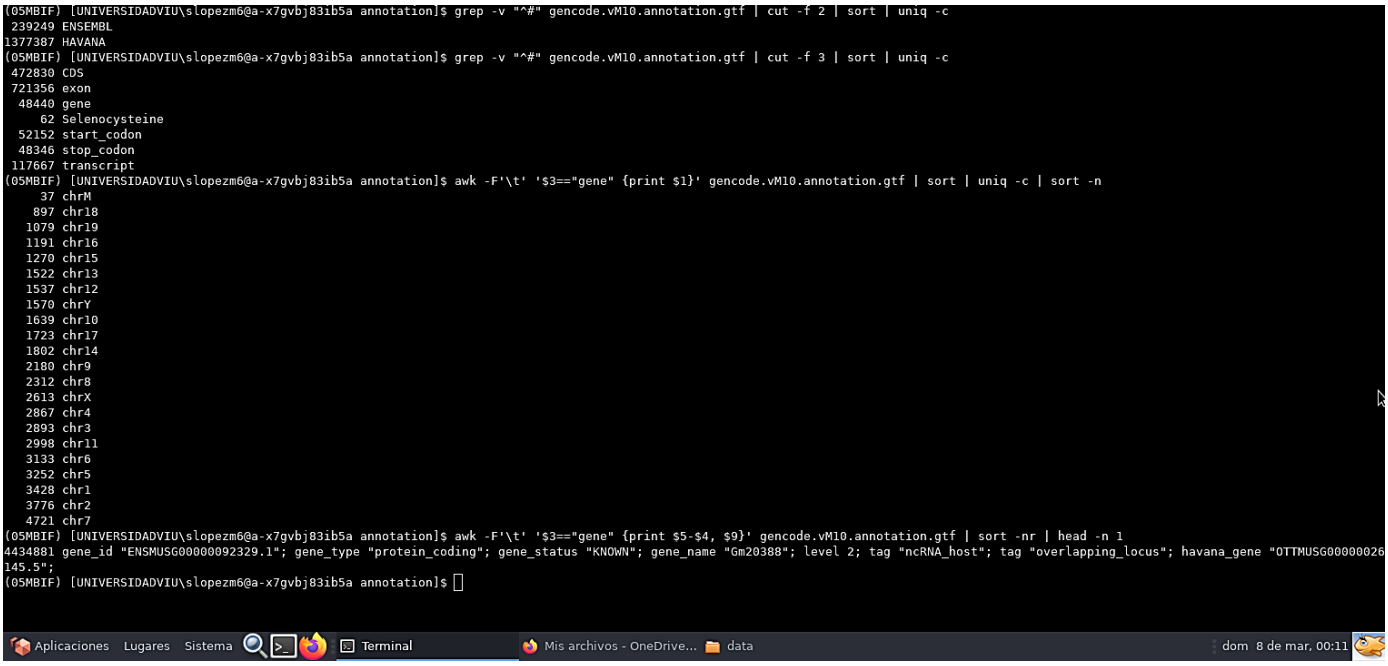
Tabla 4: *Transcript coverage profile* del alineamiento tras la utilización de *Qualimap*

[4] HBC-training. QC with STAR and Qualimap. [citado el 6 de marzo de 2026]. Disponible en: https://hbctraining.github.io/Intro-to-rnaseq-fasrc-salmon-flipped/lessons/10_QC_Qualimap.html

[5] TruSeq RNA Sample Prep v2 Guide. [citado el 6 de marzo de 2026]. Disponible en: https://support.illumina.com/downloads/truseq_rna_sample_preparation_v2_guide_15026495.html

P6. Cada lectura alineada en el archivo BAM tiene una ubicación cromosómica específica en el genoma. Ahora, para interpretar estos alineamientos, es necesario utilizar un archivo de anotaciones en formato GTF. Obtén dicho archivo y responde a las siguientes preguntas (1,5 pts):

- ¿Cuántos y cuáles son los programas o bases de datos utilizados para generar la anotación del archivo GTF? Para responder, interroga la columna **SOURCE**.
- ¿Cuál es la **FEATURE** más abundante que podemos encontrar en el archivo de anotaciones?
- ¿En qué cromosoma se encuentra la mayor cantidad de **GENES** y en cuál la menor?
- ¿Cual es el **GEN** mas largo que puedes encontrar?

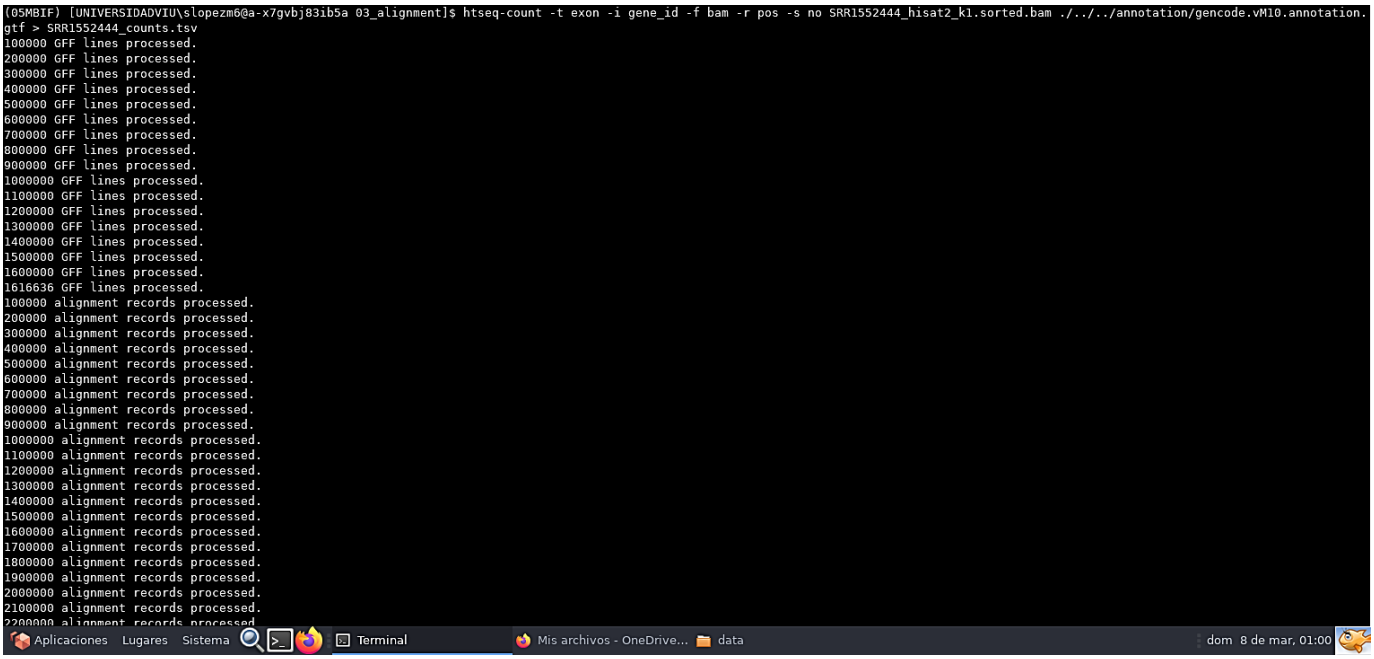


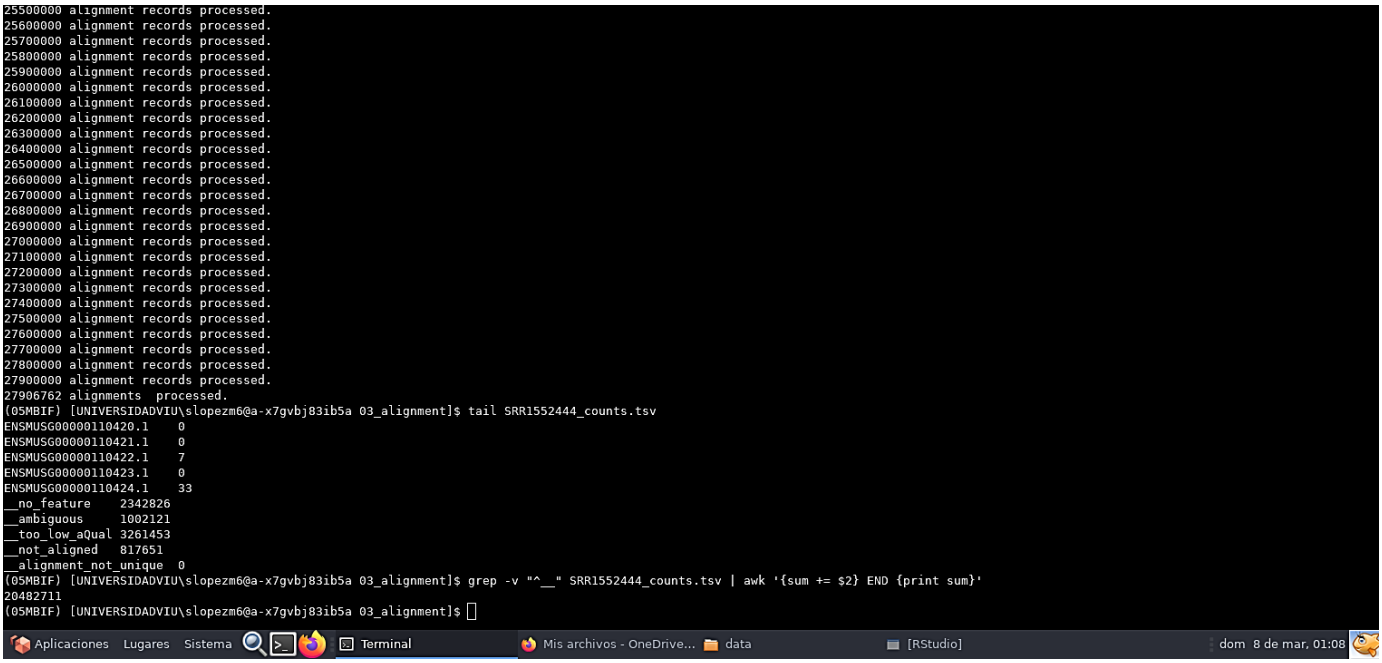
Captura de pantalla 8: teniendo en cuenta al comienzo de los archivos *GTF* puede haber comentarios que comienzan por #[6] y no deben ser tenidos en cuenta para este ejercicio, se seleccionan las columnas que corresponden y se imprimen por pantalla los resultados para contestar a las preguntas.

- En la **segunda columna** del archivo GTF (**SOURCE**), tras ordenar la información y visualizarla se puede apreciar que la información se generó a partir de **dos bases de datos:**
  1. **HAVANA:** Contribuye con 1377387 anotaciones.
  2. **ENSEMBL**: Contribuye con 239.249 anotaciones.
- Al analizar la **tercera columna** del archivo GTF (**FEATURE**) el sistema nos devuelve 8 categorías biológicas distintas que estructuran el genoma, siendo **exon la más abundante (721356)**
- El cromosoma con la **menor cantidad de genes** es el **cromosoma mitocondrial (chrM - 37 genes).** El cromosoma con la **mayor cantidad de genes** es el **cromosoma 7 (chr7 - 4721 genes).**
- **El gen más largo** que puedo encontrar **es ENSMUSG00000092329.1 y su nombre oficial es Gm20388; mide 4434881 pb.**

[6] Genbank GTF notes. [citado el 7 de marzo de 2026]. Disponible en: https://www.ncbi.nlm.nih.gov/genbank/genomes_gff/

P7. Finalmente, ejecuta el recuento de los alineamientos sobre el archivo BAM con htseq-count. Reporta los comandos utilizados y computa sobre el archivo tsv final, el porcentaje total de lecturas asignadas, no_feature, ambiguous, too_low_aQual y not_aligned. Una vez computado estos porcentajes, muéstralos con un gráfico (usando cualquier lenguaje de programación) y comenta brevemente su resultado. ¿Son porcentajes esperados en un experimento de ARN-seq? (1,5 pts)

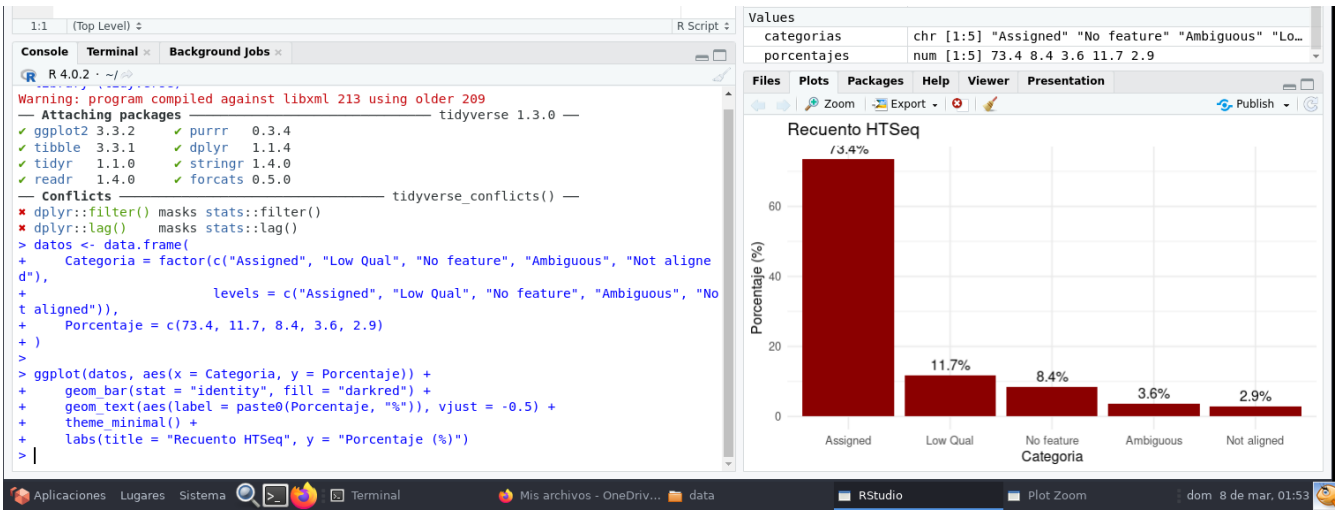




Captura de pantalla 9 y 10: realización del recuento con HTSEQ-COUNT.

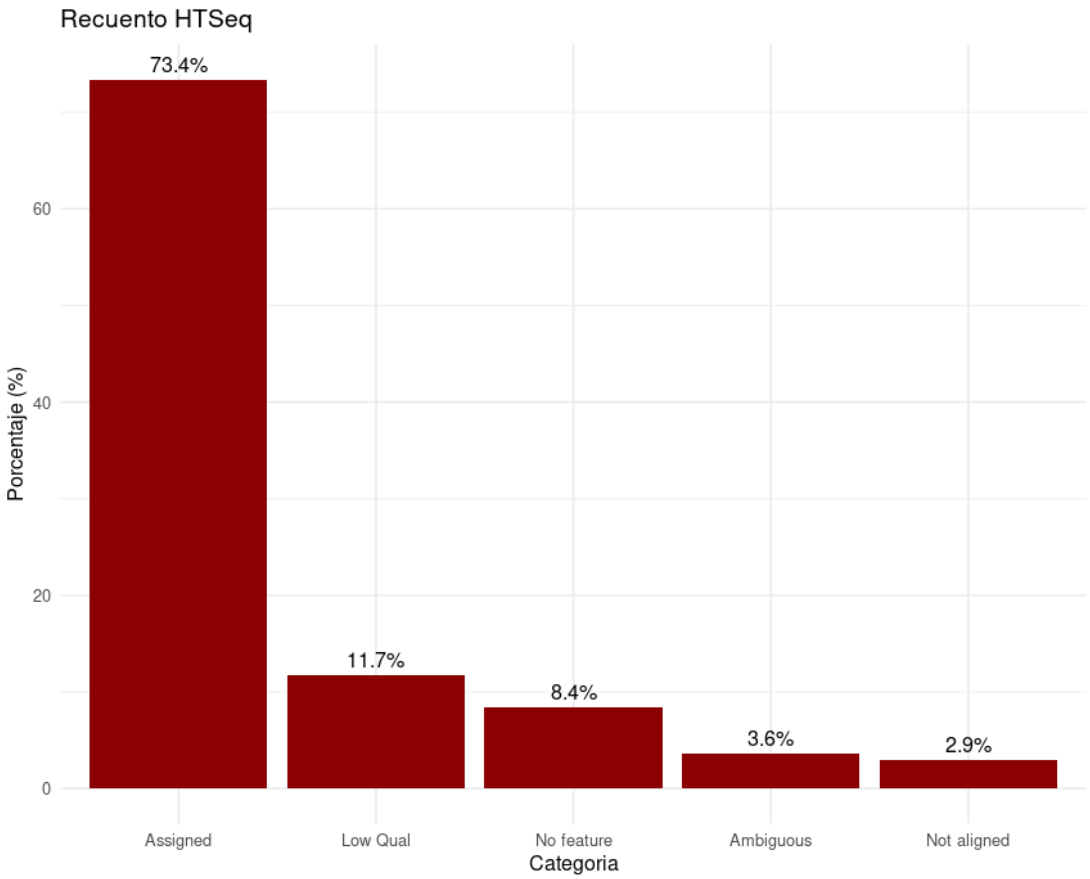
- Lecturas totales = 20482711 + 2342826 + 1002121 + 3261453 + 817651 = 27906762 lecturas (es el 100%)
- **Porcentaje total de lecturas asignadas: 73.40 %** (20482711 / 27906762)
- **No_feature: 8.40 %** (2342826 / 27906762)
- **Ambiguous: 3.59 %** (1002121 / 27906762)
- **Too_low_aQual: 11.69 %** (3261453 / 27906762)
- **Not_aligned: 2.93 %** (817651 / 27906762)

Los porcentajes obtenidos son esperables y positivos. Se observa que la gran mayoría de las lecturas han sido correctamente asignadas, lo cual demuestra buena calidad de los datos y buen alineamiento, es el objetivo principal del experimento, que haya muchos exones y que se puedan alinear bien. Los demás porcentajes se mantienen bajos[7], lo cual es bueno también y es lo que se espera en un buen experimento de ARN-seq, ya que buscamos que no haya lecturas que alineen mal en lugares que no les corresponden (%no_feature bajo), que no haya solapamiento entre genes que puedan causar ambigüedad a la hora del alineamiento (%ambiguous bajo), que haya buena calidad de las lecturas (%too_low_aQual bajo), y que la muestra sea de calidad y no tenga contaminación que entorpezca el experimento (%not_aligned bajo).



Captura de pantalla 11: Captura que abarca la terminal de *Rstudio* en la que se realizó la gráfica necesaria para este ejercicio utilizando ggplot2 en el paquete *tidyverse*.

[7] Counting reads in features with htseq-count. [citado el 8 de marzo de 2026]. Disponible en: https://htseq.readthedocs.io/en/release_0.11.1/count.html



Gráfica 5: porcentaje total de lecturas *asignadas, no_feature, ambiguous, too_low_aQual y not_aligned* en el recuento de *HTSEQ-COUNT*.