Actividad 2- *From gene counts to DEG and pathways*

Objetivo

El propósito de esta actividad es que el estudiante demuestre la adquisición de habilidades y competencias necesarias para llevar a cabo un análisis estadístico adecuado de los datos de un experimento de ARN-seq. Esto implica identificar los genes diferencialmente expresados (DEG) entre distintos grupos y realizar un análisis funcional para determinar los principales términos enriquecidos en ontología génica (GO).

Obtención de los datos

La actividad se basa en el análisis de un estudio de ARN-seq sobre la expresión génica en células basales y luminales de glándulas mamarias de ratones en distintos estados fisiológicos.

Referencia del estudio:

Fu, Nai Yang, et al. "EGF-mediated induction of Mcl-1 at the switch to lactation is essential for alveolar cell survival." *Nature Cell Biology* 17.4 (2015): 365-375.

Todo el material necesario para completar esta actividad se encuentra en la sección de: Recursos y Materiales → 03.Materiales del profesor → Proyecto_JULIO_2025.

Formato de la entrega

📌 **Entrega:**

- Utiliza esta plantilla, guárdala en **PDF** y súbela a la actividad en el Campus VIU.

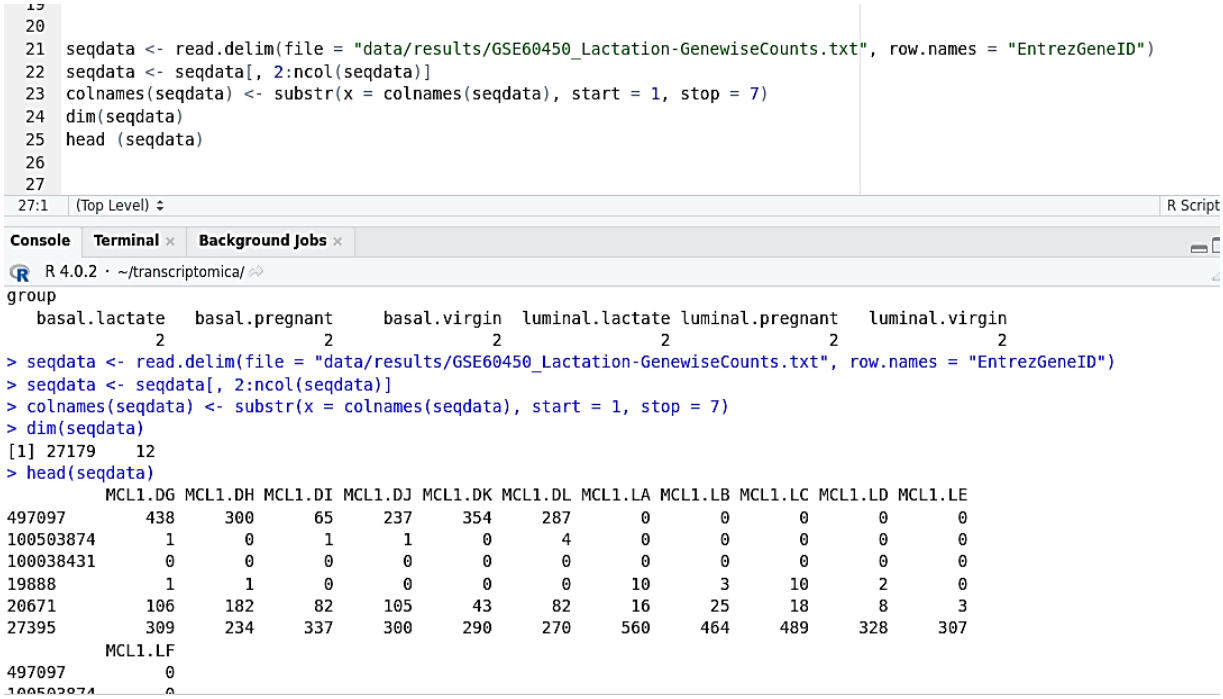
📌 **Requisitos:**

- Responde de forma clara y concisa, justificando cada respuesta.
- Usa las mismas versiones de R y de los paquetes empleados en clase.
- Incluye los comandos utilizados y capturas de pantalla de su ejecución. ❌ Evita capturas de pantalla completas de RStudio (solo muestra la salida relevante).
- Adjunta los gráficos generados, con sus correspondientes pies de figura, que respalden las respuestas.
- No expliques en detalle el funcionamiento de los comandos utilizados.
- No incluyas comandos de instalación de paquetes ni de revisión o depuración de código.
- Asegúrate de que todas las imágenes sean legibles y de buena calidad.

Preguntas

P1. Lee la matriz de recuentos llamada GSE60450_Lactation-GenewiseCounts.txt, selecciona únicamente las columnas que representan las muestras y renómbralas como hicimos en clase. Contesta a las siguientes preguntas que te permitirán conocer un poco mejor su contenido y estructura. (2 pts).

1. ¿Cuántos genes figuran en la matriz de recuentos inicial?
2. Genera un gráfico de barras con los valores máximos de conteos por muestra y comenta los resultados. ¿A qué gen se asocian en cada caso?
3. ¿Cuál es el porcentaje de genes que presentan un valor de conteos > 0 en cada muestra? Comenta brevemente los resultados.
4. Tras la conversión de los identificadores *ENTREZID* de los genes a *SYMBOL,* ¿cuántos genes no se pudieron convertir correctamente y aparecen como NA?



```
20
21 seqdata <- read.delim(file = "data/results/GSE60450_Lactation-GenewiseCounts.txt", row.names = "EntrezGeneID")
22 seqdata <- seqdata[, 2:ncol(seqdata)]
23 colnames(seqdata) <- substr(x = colnames(seqdata), start = 1, stop = 7)
24 dim(seqdata)
25 head (seqdata)
26
27
```

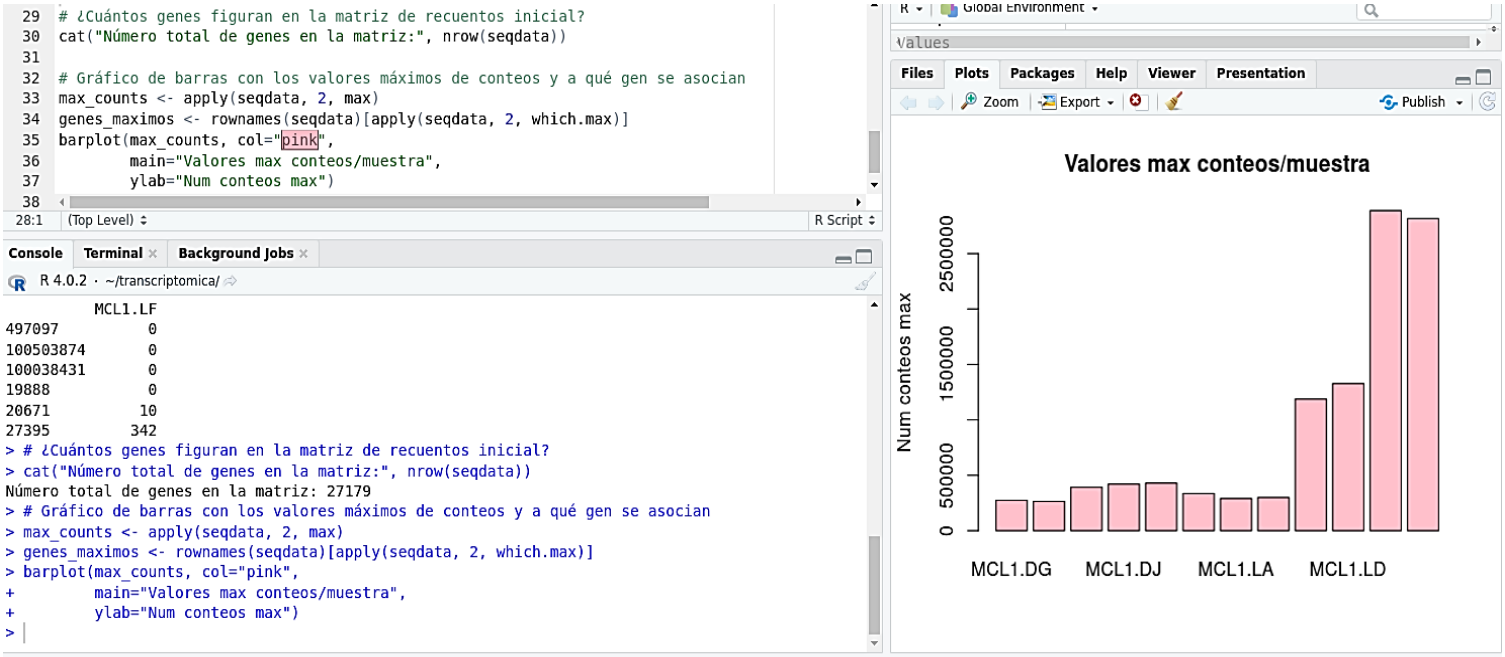
27:1 (Top Level) R Script

Console Terminal Background Jobs

R 4.0.2 · ~/transcriptomica/

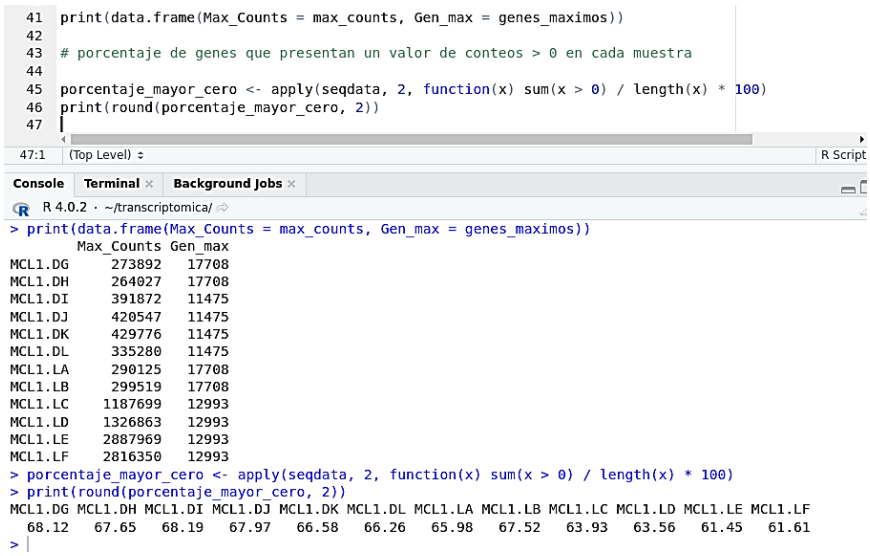
```
group
   basal.lactate   basal.pregnant     basal.virgin  luminal.lactate luminal.pregnant   luminal.virgin
               2               2               2               2               2               2
> seqdata <- read.delim(file = "data/results/GSE60450_Lactation-GenewiseCounts.txt", row.names = "EntrezGeneID")
> seqdata <- seqdata[, 2:ncol(seqdata)]
> colnames(seqdata) <- substr(x = colnames(seqdata), start = 1, stop = 7)
> dim(seqdata)
[1] 27179    12
> head(seqdata)
          MCL1.DG MCL1.DH MCL1.DI MCL1.DJ MCL1.DK MCL1.DL MCL1.LA MCL1.LB MCL1.LC MCL1.LD MCL1.LE
497097        438     300      65     237     354     287       0       0       0       0       0
100503874       1       0       1       1       0       4       0       0       0       0       0
100038431       0       0       0       0       0       0       0       0       0       0       0
19888           1       1       0       0       0       0      10       3      10       2       0
20671         106     182      82     105      43      82      16      25      18       8       3
27395         309     234     337     300     290     270     560     464     489     328     307
          MCL1.LF
497097          0
```

Captura de pantalla 1: lectura de la matriz de recuentos y selección únicamente de las columnas que representan las muestras (desde la columna 2 hasta el final de la matriz) con los nombres correspondientes según el nombre del ENTREZGENEID, abreviado hasta exactamente 7 caracteres cada uno.



Captura de pantalla 2: realización de la primera pregunta. Teniendo en cuenta que cada fila es un gen, simplemente se cuenta cuántas filas hay.

Posteriormente se procede a la realización del gráfico de la segunda pregunta, representando los valores máximos de conteos por muestra.



Captura de pantalla 3: para continuar con la segunda pregunta y ver los valores máximos de los conteos y sus genes asociados en cada caso se hace un data frame, siendo *Max_counts* los valores máximos de conteo, y *Gen_max* el gen asociado al valor máximo. Con esto se obtiene el *EntrezID* del gen que se expresa con mayor intensidad para cada muestra (que sería el *Gen_max*) y el numero de conteos para cada uno.

Después se realiza la tercera pregunta, calculando los porcentajes de genes que presentan un valor >0 en cada muestra.

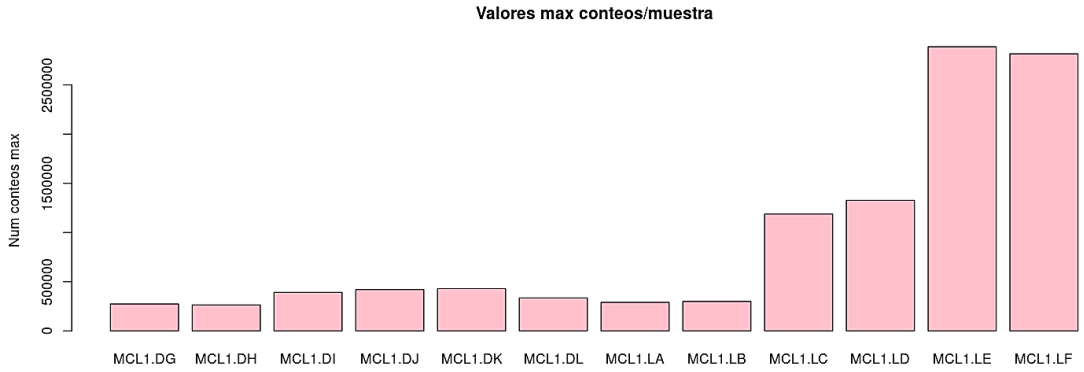


Gráfico 1: detalle del gráfico de barras con los valores máximos de conteos de cada gen asociado por muestra. Se observa una diferencia importante entre las muestras MCL1.LC MCL1.LD MCL1.LE y MCL1.LF respecto a las demás. Esto tiene un sentido biológico, ya que, como se puede ver en *sampleinfo*, estas muestras corresponden a células luminales de dos hembras gestantes (MCL1.LC y MCL1.LD), y a dos hembras lactantes (MCL1.LE y MCL1.LF). Según el *data frame* que se realizó para completar la pregunta 2 (Captura de pantalla 3), podemos ver que en estas células hay una sobreexpresión del gen *EntrezID* 12993, que es el gen de la beta-caseína, una proteína de la leche. Las células luminales de la glándula mamaria durante la preñez avanzada y la lactancia se especializan casi exclusivamente en la producción de leche, por lo que tiene sentido que terminen acaparando una gran proporción de las lecturas de secuenciación. En contraposición, tenemos las demás muestras que corresponden a la sobreexpresión de otros genes según el *data frame*. Las muestras MCL1.DG, MCL1.DH, MCL1.DI, MCL1.DJ, MCL1.DK y MCL1.DL corresponden a muestras de células basales. Las células basales de la glándula mamaria son células mioepiteliales, responsables de la contracción muscular para la liberación de la leche, pero no de su fabricación, por eso aquí no va a aparecer expresada de forma importante la beta-caseína. En las muestras MCL1.LA, MCL1.LB, MCL1.DG, MCL1.DH, que son de ratonas vírgenes, el gen que predomina es el *EntrezID* 17708, que corresponde a la Citocromo C Oxidasa I Mitocondrial (MT-CO1), esto tiene sentido porque si son vírgenes no necesitan hipertrofiar ningún musculo mamario ni producir leche, por lo que simplemente se dedican a producir la energía básica para mantener a la célula viva. Para las células basales MCL1.DI, MCL1.DJ, MCL1.DK y MCL1.DL el gen que predomina es el *EntrezID* 11475, que corresponde al gen de la Actina Alfa 2 del músculo liso. Esto corresponde también biológicamente porque las MCL1.DI y MCL1.DJ son ratonas preñadas, y las MCL1.DK y MCL1.DL son ratonas gestantes, por lo que en sus células basales si se hipertrofia el músculo liso para producir la liberación de la leche.

```
43  # porcentaje de genes que presentan un valor de conteos > 0 en cada muestra
44
45  porcentaje_mayor_cero <- apply(seqdata, 2, function(x) sum(x > 0) / length(x) * 100)
46  print(round(porcentaje_mayor_cero, 2))
47
48  # Tras la conversión de ENTREZID a SYMBOL, ¿cuántos aparecen como NA?
49
50  library(org.Mm.eg.db)
51  symbols <- mapIds(org.Mm.eg.db, keys=rownames(seqdata), column="SYMBOL", keytype="ENTREZID", multiVals="first")
52  print(sum(is.na(symbols)))
53
```

49:1 (Top Level) R Script

Console Terminal Background Jobs

R 4.0.2 · ~/transcriptomica/

```
Loading required package: IRanges
Loading required package: S4Vectors

Attaching package: 'S4Vectors'

The following object is masked from 'package:base':

    expand.grid


> symbols <- mapIds(org.Mm.eg.db, keys=rownames(seqdata), column="SYMBOL", keytype="ENTREZID", multiVals="first")
'select()' returned 1:1 mapping between keys and columns
> print(sum(is.na(symbols)))
[1] 1275
```

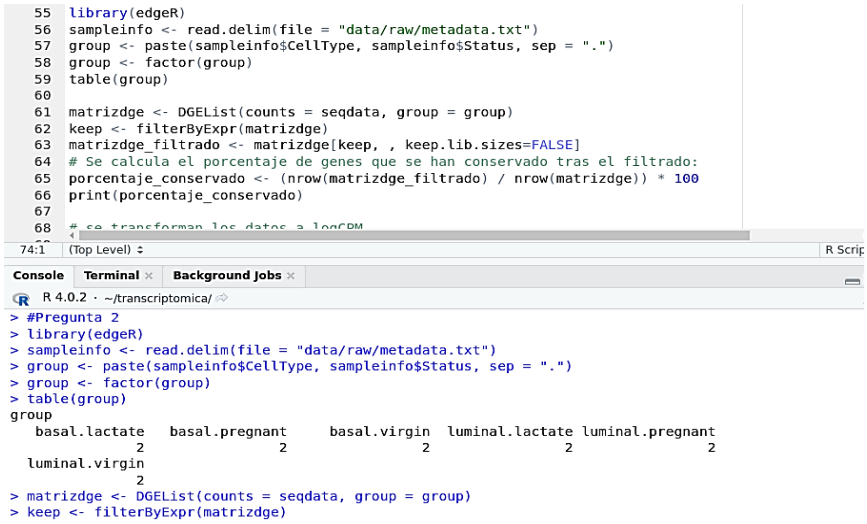
Captura de pantalla 4: utilizando *org.Mm.eg.db* se realiza la cuarta pregunta.

- Resumen final de respuestas de la pregunta 1:
    - En la matriz de recuentos inicial **figuran 27179 genes (captura de pantalla 2).** Esto también se puede ver indirectamente en la captura de pantalla 1 cuando se observan las dimensiones del objeto con *dim(seqdata)* ya que cada gen es una fila, y al darnos las dimensiones de la matriz nos da también el número de genes.
    - **El gráfico de barras con los valores máximos de conteos por muestra fue generado en la *Captura de pantalla 2* y se puede observar en detalle en el *Gráfico 1.*** Al observar el gráfico de barras se observa una diferencia importante entre las muestras luminales MCL1.LC MCL1.LD MCL1.LE y MCL1.LF respecto a las demás en la expresión del gen de la beta-caseína. En las muestras basales o de ratones vírgenes, los máximos corresponden a la expresión mayoritaria de otros tipos de genes ya que no les corresponde producir leche, por lo que no aparece la beta-caseína como el gen principal.
        - ¿A qué gen se asocian en cada caso? → **La respuesta a esta pregunta está explicada en el Gráfico 1,** utilizando la información conjunta del gráfico y del *data frame* creado en la Captura de pantalla 3. De forma resumida**,** el gen que aparece expresado con mayor intensidad en las **células luminales de las ratonas preñadas o lactantes es el *EntrezID* 12993, que es el gen de la beta-caseína; en ratonas vírgenes (tanto si las muestras son de células luminales o basales), el gen que predomina es el** EntrezID **17708, que corresponde a la Citocromo C Oxidasa I Mitocondrial (MT-CO1**); y el gen que se asocia de forma mayoritaria a **células basales de ratonas preñadas o lactantes es el EntrezID 11475, que corresponde al gen de la Actina Alfa 2 del músculo liso.**
    - El porcentaje de genes que presentan un valor de conteos > 0 en cada muestra **aparece reflejado en la Captura de pantalla 3. Como comentario, los resultados muestran que en todas las muestras se expresa entre un 61% y un 68% del genoma total de 27179 genes. Esto es lógico ya que ninguna célula transcribe la totalidad de su genoma simultáneamente ya que esto sería un gasto enorme de energía, por lo que eses porcentajes son correctos. En las células luminales en las que aparece sobreexpresada la beta-caseína, el porcentaje del conteo es ligeramente inferior en comparación con los demás. Esto puede ser porque el gen aparece en un nivel tan alto de expresión, que genes que están en valores mucho más bajos pueden no ser considerados como activos en comparación y no son contabilizados en el conteo (sesgo de composición)[1].**
    - Tras la conversión de los identificadores ENTREZID de los genes a SYMBOL, **1275 genes no se pudieron convertir correctamente y aparecen como NA (Captura de pantalla 4).** Esto suele corresponder a secuencias transcritas desconocidas, ARN no codificante, pseudogenes, etc.

[1] Beck, K., Turco, G., Bradnam, K., Rijnkels, M., Nommsen-Rivers, L., Korf, I. and Lemay, D. (2014), Adjustment of RNA-Seq data for the effect of highly abundant transcripts: a case study in milk production (622.4). The FASEB Journal, 28: 622.4. https://doi.org/10.1096/fasebj.28.1_supplement.622.4

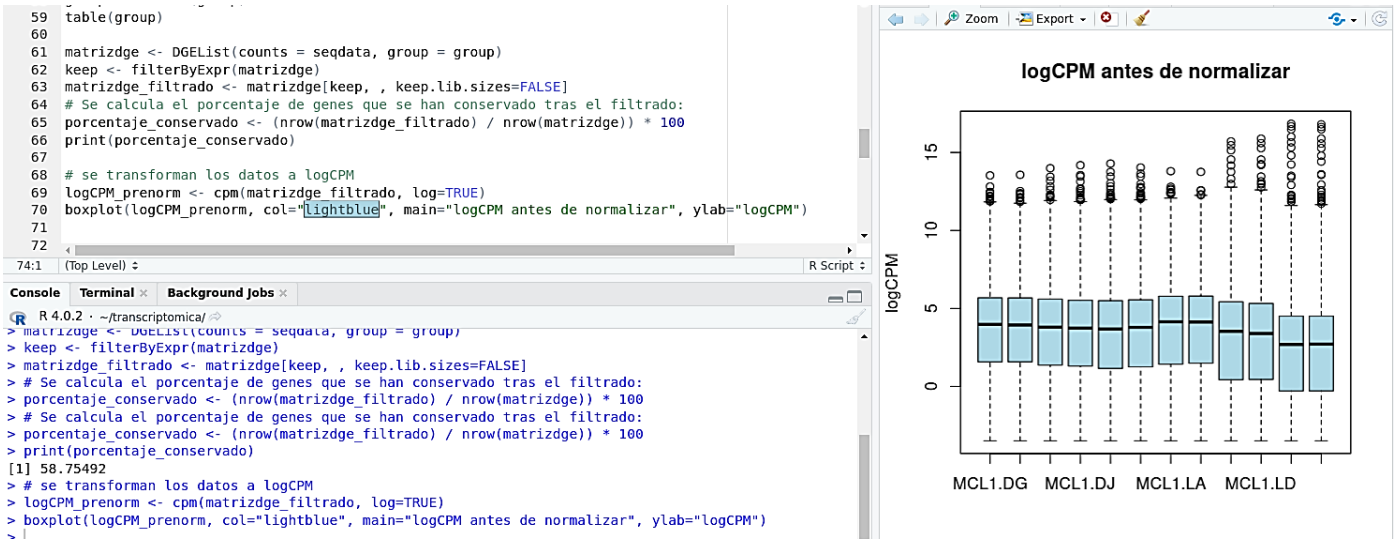
P2. Convierte la matriz de recuentos en un objeto DGEList y elimina los genes de baja expresión empleado la función filterByExpr (1 pts).

- ¿Qué porcentaje de genes se mantienen tras el filtrado?
- Realiza un gráfico de cajas (*boxplot*) con los conteos transformados a logCPM antes de computar los factores de normalización y comenta su resultado.



Captura de pantalla 5: se realiza la lectura del archivo de texto *metadata.txt* para obtener los nombres de los tipos celulares (basal, luminal) y a qué estado reproductivo corresponden (virgin, pregnant, lactate); con *paste* se unen las columnas que contienen esa información separada por un punto. Se cuentan cuantas hembras corresponden por grupo y se muestran en una tabla, finalmente resultan 6 grupos de 2 hembras cada uno. Esto es importante porque el *group* en adelante será la "etiqueta" que organice las muestras de las hembras a la hora de realizar la matriz de conteos y los análisis posteriores.

Posteriormente se realiza la matriz de recuentos con DGElist; y se procede a la eliminación de los genes de baja expresión con filterByExpr.



Captura de pantalla 6: continuación del ejercicio 2 con el cálculo del porcentaje de genes que se mantienen y realización del boxplot con los conteos transformados a logCPM antes de normalizar.

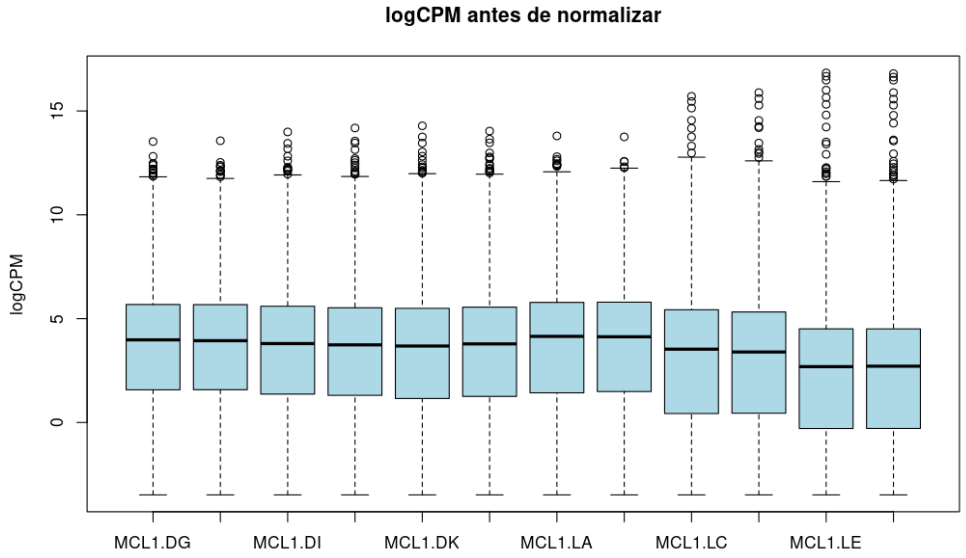


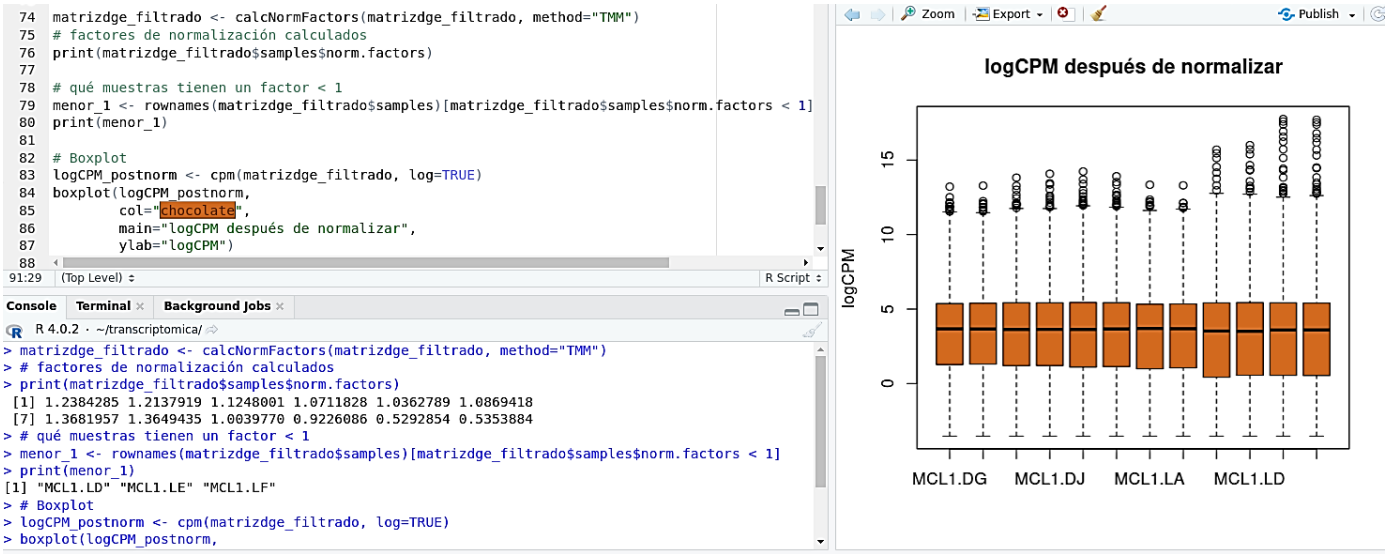
Gráfico 2: detalle del boxplot con los conteos transformados a logCPM antes de normalizar.

- Respuestas de la pregunta 2:
  - Tras aplicar la función *filterByExpr* para eliminar los genes con conteos muy bajos que carecen de significación estadística**, se mantiene un 58,75 % de los genes originales** de la matriz (Captura de pantalla 6).
  - Tras realizar el boxplot (Gráfico 2), se puede destacar al verlo que las medianas de los datos transformados a logCPM antes de normalizar no están alineadas[2]. Las medianas de las últimas cuatro muestras correspondientes a MCL1.LC, MCL1.LD, MCL1.LE y MCL1.LF (que eran células luminales de ratonas preñadas y lactantes) tienen valores de logCPM cercanas a 3 y están hundidas respecto a las demás, mientras que las medianas, tanto de muestras de células basales como de las ratonas vírgenes de cualquier grupo, mantienen un valor de logCPM más cercano a 4 y sus medianas están relativamente alineadas entre ellas en comparación con el grupo de células luminales preñadas y gestantes. A mayores las muestras luminales de lactantes y preñadas presentan numerosos valores atípicos (*outliers*). Esto ilustra visualmente el **sesgo de composición** del que hablaba antes, ya que la expresión del gen de la beta-caseína consume la mayor parte de la profundidad de secuenciación, y esto provoca que la distribución global del resto de los genes se desplace artificialmente hacia abajo.

P3. **Siguiendo el análisis con la muestra filtrada, computa sus factores de normalización mediante el método TMM (1,5 pt).**

[2] Maria Doyle, Belinda Phipson, Jovana Maksimovic, Anna Trigos, Matt Ritchie, Harriet Dashnow, Shian Su, Charity Law, 2: RNA-seq counts to genes (Galaxy Training Materials). https://training.galaxyproject.org/training-material/topics/transcriptomics/tutorials/rna-seq-counts-to-genes/tutorial.html

- Realiza un gráfico de cajas (*boxplot*) con los conteos transformados a logCPM tras computar los factores de normalización y compáralo con el obtenido en la pregunta P2.
- ¿Qué muestras presentan un factor de normalización (*norm.factors*) < 1?
- Genera un gráfico MDS empleando colores distintivos para las muestras analizadas. Comenta brevemente cómo se asocian o diferencian dichas muestras.



Captura de pantalla 7: se realiza la normalización de los datos de la matriz de conteos filtrada en el ejercicio anterior y se visualizan los resultados, posterior a ello se filtran qué muestras tienen un factor <1. Se realiza el boxplot con el logCPM después de la normalización.

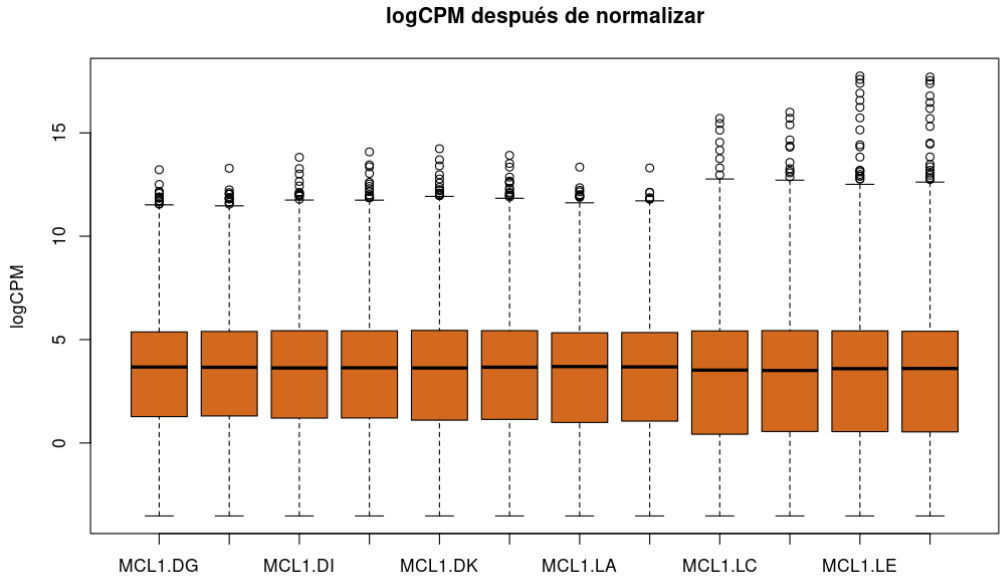
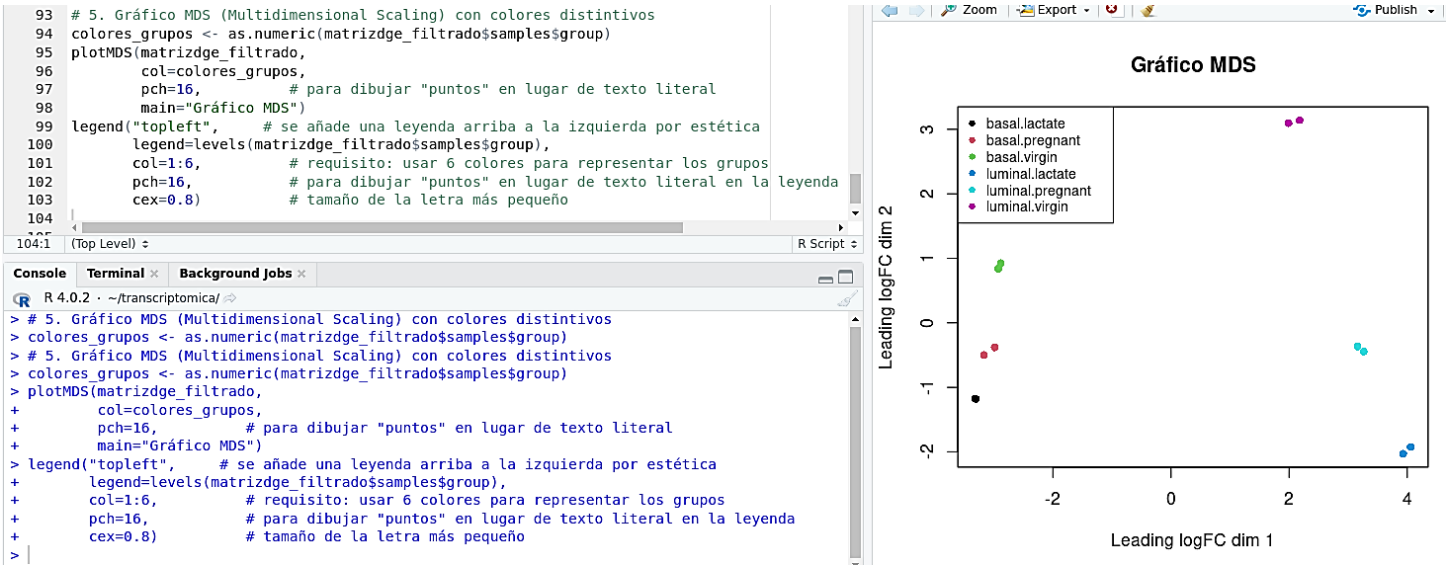


Gráfico 3: detalle del boxplot con los datos de logCPM tras la normalización.



Captura de pantalla 8: realización de gráfico MDS empleando colores distintivos para las muestras analizadas. Al haber marcado el *group* "as *numeric*" y transformarlo *en colores_grupos,* cada grupo se convierte en un número, y en R, a la hora de hacer funciones base como MDS o boxplot, cada número se interpreta automáticamente como color (el 1 es negro, el 2 es rojo, el 3 es verde, el 4 es azul...). Así se transforma un grupo en colores de forma sencilla sin especificar, como *basal.lactate* en un punto negro en la gráfica y viceversa.

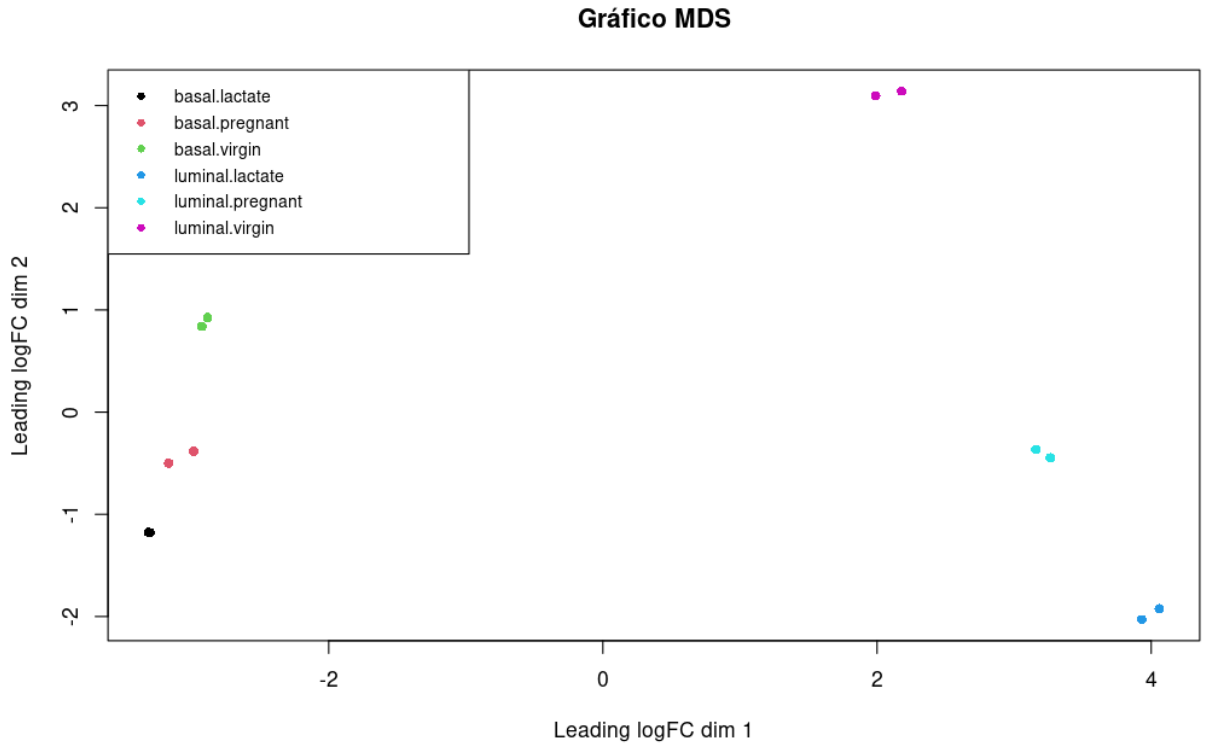


Gráfico 4: detalle del gráfico MDS. Cada punto correspondería con una muestra y un color según se refleja en la leyenda (esquina superior izquierda).

- Respuestas de la pregunta 3:
    - En el Gráfico 3 se puede observar el nuevo boxplot con los datos normalizados. Al comparar el boxplot previo a la normalización (P2) con el actual, se observa un cambio en la distribución de los datos. En el gráfico de la P2, las medianas de las muestras luminales en estados de preñez y lactancia estaban hundidas debido al sesgo de composición, pero **ahora tras computar los factores de normalización, las medianas de todas las muestras se han alineado horizontalmente (Gráfica 3) en torno al mismo valor de logCPM (aprox. 4).** Esto demuestra que **el factor de normalización ha corregido el sesgo causado por la sobreexpresión de la beta-caseína en las muestras afectadas**. Aún así, se siguen observando numerosos outliers en las muestras luminales de hembras preñadas y lactantes, porque lo que se busca con la normalización es "corregir el hundimiento" del boxplot, que es una distribución irreal y provoca un desvío en la mediana de esas cuatro muestras (MCL1.LC, MCL1.LD, MCL1.LE y MCL1.LF), pero no se pueden corregir los outliers verdaderos, que serían las proteínas sobreexpresadas de la leche en esas muestras que sobresalen del boxplot.
    - **Las muestras que presentan un factor de normalización < 1 corresponden a una muestra de células luminales de ratona preñada (MCL1.LD) y ambas las dos luminales de ratonas lactantes (MCL1.LE y MCL1.LF).** La otra muestra de células luminales de hembra preñada, la MCL1.LC, por poco no cae en esta categoría también, ya que su factor de normalización es justamente 1.0039, pero al ser 1 prácticamente no se contempla (Captura de pantalla 7).
    - El gráfico MDS (Gráfico 4) agrupa las muestras según la similitud global de sus perfiles transcripcionales, y las distancias se calculan en dos dimensiones (los ejes X e Y, en este caso dim1 y dim2 respectivamente), basándose en los genes que presentan los mayores cambios de expresión (*Leading logFC, siendo FC el fold change*) entre cada par de muestras[3]. En la dimensión 1 (eje X), se ve una gran separación entre muestras con un gap intermedio, coincidiendo todas las muestras del lado izquierdo con las células basales, y las del lado derecho con las células luminales, sin posibilidad de solapamiento entre grupos. Esto demuestra que el tipo celular es el factor principal que caracteriza al transcriptoma, muy por encima de los cambios fisiológicos de las hembras a las que se le tomó la muestra. Por otro lado, en la dimensión 2 (eje Y) se ve el efecto del estado fisiológico de la glándula mamaria, aunque aquí los espacios entre grupos sean mucho menos pronunciados en comparación con la variable anterior (se puede apreciar como entre el grupo de células basales en hembras lactantes la diferencia es tan poca que se superponen los puntos negros). De todos modos, si se observan los grupos de forma general, se puede apreciar como las muestras se segregan a lo largo del eje Y siguiendo la cronología biológica: estado virgen (tanto en el grupo de basales como de luminales, son los grupos que están más arriba en la gráfica) → gestación (toman una posición intermedia en la gráfica) → lactancia (los grupos más cercanos a la base de la gráfica).

[3] Maria Doyle, Belinda Phipson, Jovana Maksimovic, Anna Trigos, Matt Ritchie, Harriet Dashnow, Shian Su, Charity Law, 2: RNA-seq counts to genes (Galaxy Training Materials). https://training.galaxyproject.org/training-material/topics/transcriptomics/tutorials/rna-seq-counts-to-genes/tutorial.html

Esto confirma que el proceso reproductivo provoca cambios transcriptómicos que evolucionan según avanza el proceso biológico de la reproducción.

P4. Calcula los tres tipos de dispersión del objeto DGEList creado (0,5 pt).

```
# matriz de diseño
design <- model.matrix(~ 0 + matrizdge_filtrado$samples$group)
colnames(design) <- levels(matrizdge_filtrado$samples$group)

# estimar dispersiones
matrizdge_filtrado <- estimateDisp(matrizdge_filtrado, design = design, robust = TRUE)

# ajustar el modelo GLM)
fit <- glmQLFit(matrizdge_filtrado, design = design, robust = TRUE)

# se buscan las dispersiones de los genes segun su ENTREZID
genes_entrezid <- c("69237", "497097", "20671")

tabla_dispersiones <- data.frame(
  Trended_Dispersion = matrizdge_filtrado$trended.dispersion[rownames(matrizdge_filtrado) %in% genes_entrezid],
  Tagwise_Dispersion = matrizdge_filtrado$tagwise.dispersion[rownames(matrizdge_filtrado) %in% genes_entrezid]
)
```

129:1 (Top Level) R Script

Console Terminal Background Jobs

R 4.0.2 · ~/transcriptomica/

```
> # matriz de diseño
> design <- model.matrix(~ 0 + matrizdge_filtrado$samples$group)
> colnames(design) <- levels(matrizdge_filtrado$samples$group)
> # estimar dispersiones
> matrizdge_filtrado <- estimateDisp(matrizdge_filtrado, design = design, robust = TRUE)
> # ajustar el modelo GLM)
> fit <- glmQLFit(matrizdge_filtrado, design = design, robust = TRUE)
> # se buscan las dispersiones de los genes segun su ENTREZID
> genes_entrezid <- c("69237", "497097", "20671")
> tabla_dispersiones <- data.frame(
+   Trended_Dispersion = matrizdge_filtrado$trended.dispersion[rownames(matrizdge_filtrado) %in% genes_entrezid],
```

Captura de pantalla 9: realización de la matriz de diseño para posteriormente estimar las dispersiones de los genes *Imp4, Xkr4 y Sox17.* Se debe tener en cuenta que en el objeto *DGElist* el nombre de los genes estaba indicado por su *ENTREZID* no por el *SYMBOL* por lo que ahora para buscar se debe buscar el *ENTREZID* de cada uno como se muestra en la captura (Imp4 = 69237; Xkr4= 497097 y Sox17= 20671).

```
  Trended_Dispersion = matrizdge_filtrado$trended.dispersion[rownames(matrizdge_filtrado) %in% genes_entrezid],
  Tagwise_Dispersion = matrizdge_filtrado$tagwise.dispersion[rownames(matrizdge_filtrado) %in% genes_entrezid]
)
rownames(tabla_dispersiones) <- rownames(matrizdge_filtrado)[rownames(matrizdge_filtrado) %in% genes_entrezid]

print(tabla_dispersiones)
print(matrizdge_filtrado$common.dispersion)
# coeficientes
print(fit$coefficients[rownames(fit$coefficients) %in% genes_entrezid, ])
```

127:1 (Top Level) R Sc

Console Terminal Background Jobs

R 4.0.2 · ~/transcriptomica/

```
+   Trended_Dispersion = matrizdge_filtrado$trended.dispersion[rownames(matrizdge_filtrado) %in% genes_entrezid],
+   Tagwise_Dispersion = matrizdge_filtrado$tagwise.dispersion[rownames(matrizdge_filtrado) %in% genes_entrezid]
+ )
> rownames(tabla_dispersiones) <- rownames(matrizdge_filtrado)[rownames(matrizdge_filtrado) %in% genes_entrezid]
> print(tabla_dispersiones)
       Trended_Dispersion Tagwise_Dispersion
497097        0.020729697        0.138184485
20671         0.029792363        0.082959048
69237         0.009553854        0.006179059
> # coeficientes
> print(fit$coefficients[rownames(fit$coefficients) %in% genes_entrezid, ])
       basal.lactate basal.pregnant basal.virgin luminal.lactate luminal.pregnant luminal.virgin
497097     -11.13850     -12.017283   -11.227167       -19.03407       -19.034069     -19.034069
20671      -12.76802     -12.514759   -12.151626       -14.50898       -14.305090     -14.148488
69237      -10.04094      -9.322426    -9.487091       -10.03263        -9.309989      -9.489373
> print(matrizdge_filtrado$common.dispersion)
[1] 0.01344131
>
```

Captura de pantalla 10: realización de los coeficientes de los 6 grupos experimentales para los genes *Imp4, Xkr4 y Sox17* nuevamente utilizando el *ENTREZID* para denominarlos tras ajustar el modelo GLM con la función *glmQLFit* (el uso de la función se aprecia en la Captura de pantalla 9). Calculo final de la dispersión común.

```
131
132  plotBCV(matrizdge_filtrado, main="BCV dispersiones")
133  plotQLDisp(fit, main="ajuste de dispersión")
134
132:53  (Top Level)

Console  Terminal  Background Jobs
R 4.0.2 · ~/transcriptomica/
> plotBCV(matrizdge_filtrado, main="BCV dispersiones")
> plotQLDisp(fit, main="ajuste de dispersión")
>
```

Captura de pantalla 11: para finalizar se realiza un *plotBCV* y un *plotQLDDisp* para visualizar los resultados obtenidos. También se añade el cálculo de la dispersión común, aunque el primer apartado del ejercicio solo habla de la *trended* y la *tagwise dispersion*, el enunciado indica calcular los tres tipos de dispersión.

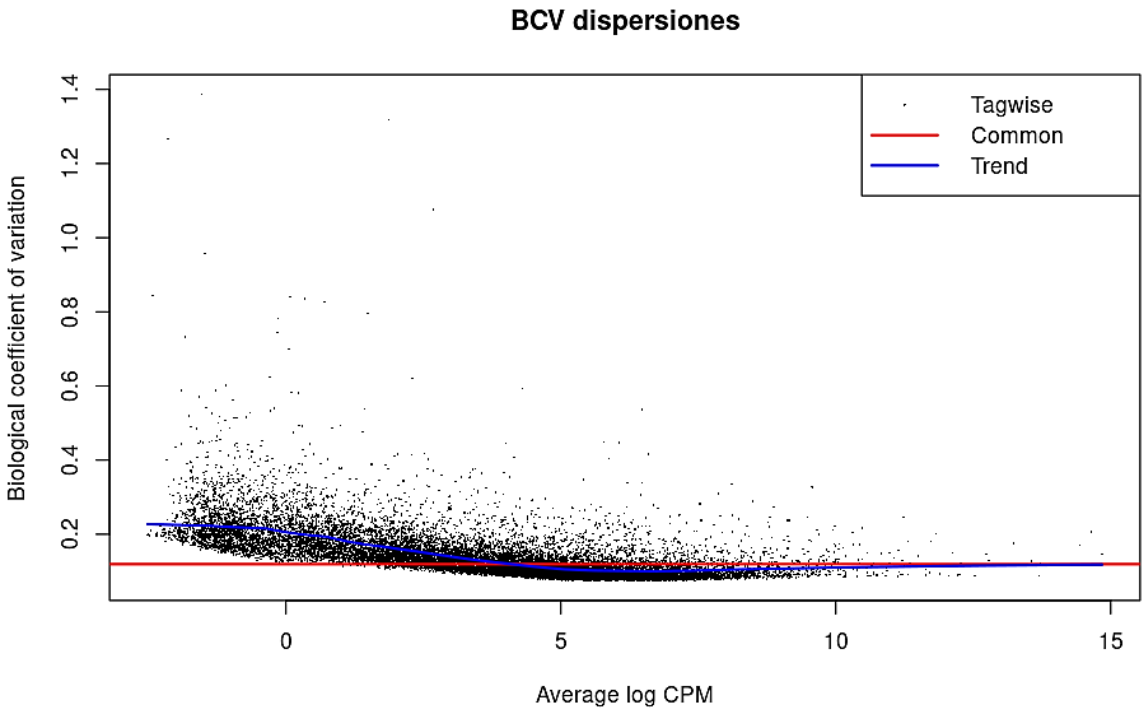


Gráfico 6: gráfico BCV (Biological Coefficient of Variation). La variabilidad es mayor en genes de baja expresión y se estabiliza en genes altamente expresados. La línea azul muestra la tendencia general (*trend dispersion*); los puntos negros representan a los genes (*tagwise dispersion*), la línea roja muestra la dispersión común.

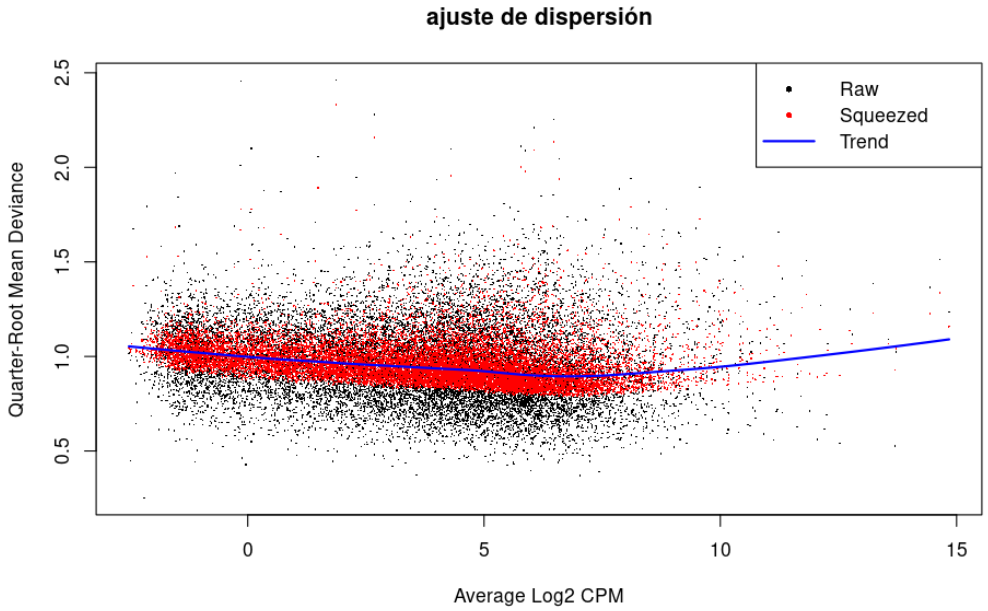


Gráfico 7: gráfico QL (Quasi-Likelihood Disp). Muestra cómo el ajuste del modelo ha funcionado y ha empujado las dispersiones extremas de los genes hacia la tendencia general (línea azul). Los puntos negros representan la dispersión natural de los genes, los puntos rojos representan la dispersión a la que fueron "forzados" tras el ajuste del modelo.

- ¿Cuáles son los valores de *trended dispersion* y *tagwise dispersion* para los genes ***Imp4***, ***Xkr4*** y ***Sox17***?

Gen (Entrez ID)	Trended Dispersion	Tagwise Dispersion
Imp4 (69237)	0.009553854	0.006179059
Xkr4 (497097)	0.020729697	0.138184485
Sox17 (20671)	0.029792363	0.082959048

Tabla 1: valores de *trended dispersion* y *tagwise dispersion* para los genes seleccionados, teniendo en cuenta su *ENTREZID*.

Según las dispersiones vistas en la Tabla 1, el gen *Imp4* se presenta como un gen con una dispersión estable y predecible, no tendrá una corrección importante (0.009 vs 0.006). Sin embargo, los genes *Xkr4* y *Sox17* tienen una diferencia de dispersión mucho mayor, se espera que al realizar el ajuste con la función *glmQLFit* estos se vean corregidos.

- Tras ajustar el modelo GLM con la función *glmQLFit*, ¿qué valores presentan los *coefficients* de los seis grupos experimentales para los genes ***Imp4***, ***Xkr4*** y ***Sox17***?

Gen (ID)	Basal Lactante	Basal Preñada	Basal Virgen	Luminal Lactante	Luminal Preñada	Luminal Virgen
Imp4	-10.04094	-9.322426	-9.487091	-10.03263	-9.309989	-9.489373
Xkr4	-11.13850	-12.017283	-11.227167	-19.03407	-19.034069	-19.034069
Sox17	-12.76802	-12.514759	-12.151626	-14.50898	-14.305090	-14.148488

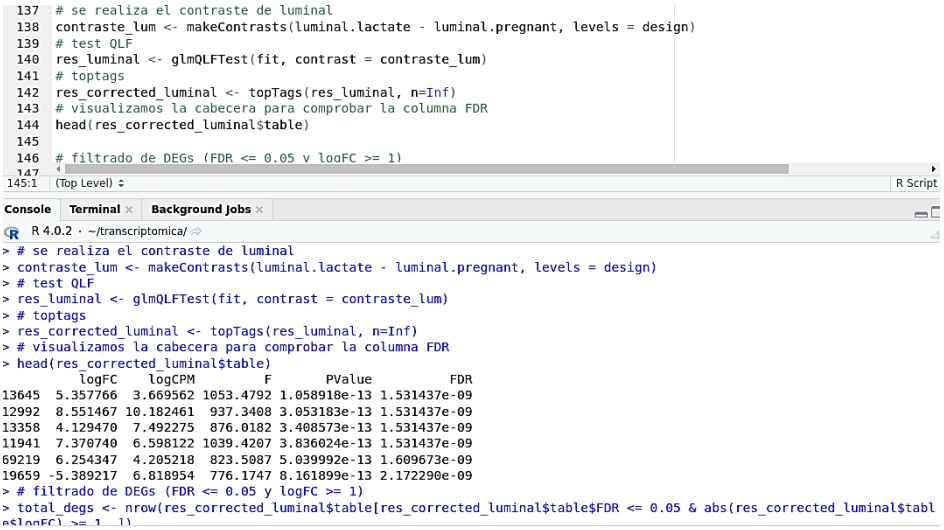
Tabla 2: *coefficients* de los seis grupos experimentales para los genes seleccionados tras el ajuste con *glmQLFit*

Viendo la tabla de coeficientes, teniendo en cuenta que los números negativos representan genes poco expresados, y cuanto "más negativos son", menos expresados están, se puede decir que el gen Xkr4 parece exclusivo de las células basales (es mucho "más negativo" en las luminales vs las basales, por lo que se supone que en las luminales prácticamente no se expresa). Sox17 tiene una expresión similar al gen anterior, aunque menos pronunciado. Imp4 es estable en todos los grupos, por lo que no parece estar afectado por el grupo celular ni el estado fisiológico.

P5. Utiliza la función *glmQLFTest* para realizar la prueba de hipótesis nula en la siguiente comparación:

- *Luminal.lactate vs luminal.pregnant*

Utiliza la función *topTags* sobre la prueba realizada anteriormente y observa cómo se genera una nueva columna con la corrección de la hipótesis nula a FDR (2,5 pts).



Captura de pantalla 12: se define la comparativa entre los grupos *luminal.lactate* y *luminal.pregnant* y se hace el estudio de expresión diferencial de los genes que constan en los grupos. Se genera la columna FDR con *topTags*, haciendo con esto la corrección de pruebas múltiples (Benjamini-Hochberg) para filtrar el experimento de posibles falsos positivos.

```
146 # filtrado de DEGs (FDR <= 0.05 y logFC >= 1)
147 total_degs <- nrow(res_corrected_luminal$table[res_corrected_luminal$table$FDR <= 0.05 & abs(res_corrected_luminal$
148 print(total_degs)
149 is.de_luminal <- decideTests(res_luminal, adjust.method = "BH", p.value = 0.05, lfc = 1)
150 # resumen de degs
151 summary(is.de_luminal)
152
```

145:1 (Top Level) R Script

Console Terminal Background Jobs

R 4.0.2 · ~/transcriptomica/

```
13358  4.129470  7.492275  876.0182 3.408573e-13 1.531437e-09
11941  7.370740  6.598122 1039.4207 3.836024e-13 1.531437e-09
69219  6.254347  4.205218  823.5087 5.039992e-13 1.609673e-09
19659 -5.389217  6.818954  776.1747 8.161899e-13 2.172290e-09
> # filtrado de DEGs (FDR <= 0.05 y logFC >= 1)
> total_degs <- nrow(res_corrected_luminal$table[res_corrected_luminal$table$FDR <= 0.05 & abs(res_corrected_luminal$tabl
e$logFC) >= 1, ])
> print(total_degs)
[1] 3381
> is.de_luminal <- decideTests(res_luminal, adjust.method = "BH", p.value = 0.05, lfc = 1)
> # resumen de degs
> summary(is.de_luminal)
       1*luminal.lactate -1*luminal.pregnant
Down                                    1576
NotSig                                 12588
Up                                      1805
>
```

Captura de pantalla 13: se aplica el punto de corte con *FDR <= 0.05* y un valor absoluto de *logFC >= 1.* Los genes restantes tras el filtrado, etiquetados como “up” o “down” son 3381, que se pueden ver desglosados en el *summary* final; los genes que no cumplían los criterios del umbral se etiquetan como “*NotSig*” (no son significativos).

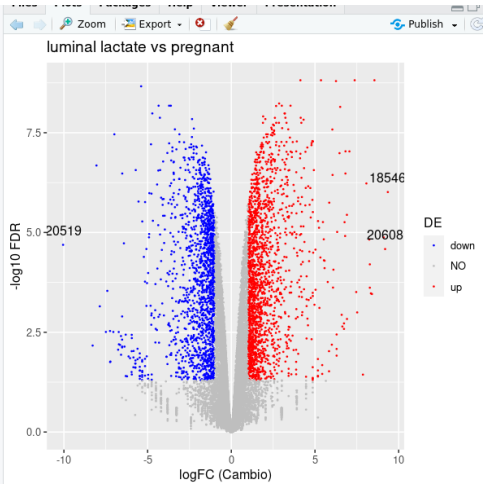
```
153 #volcano plot
154 library(ggplot2)
155 data <- res_corrected_luminal$table
156 data$DE <- "NO"
157 data$DE[data$logFC >= 1 & data$FDR <= 0.05] <- "up"
158 data$DE[data$logFC <= -1 & data$FDR <= 0.05] <- "down"
159 # se buscan los tres genes con logFC mas alto para el volcano plot
160 degs_solo <- data[data$DE != "NO", ]
161 genes_top3 <- degs_solo[order(abs(degs_solo$logFC), decreasing = TRUE), ][1:3, ]
162 print(genes_top3[, c("logFC", "FDR")])
163 # termina el volcano plot
164 ggplot(data, aes(x = logFC, y = -log10(FDR), color = DE)) +
165   geom_point(size = 0.2) +
166   scale_color_manual(values = c("NO" = "grey", "up" = "red", "down" = "blue")) +
167   geom_text(data = genes_top3, aes(label = rownames(genes_top3)),
168             vjust = -1, color = "black", show.legend = FALSE) +
169   labs(title = "luminal lactate vs pregnant",
170        x = "logFC (Cambio)", y = "-log10 FDR")
171
```

171:1 (Top Level) R Script

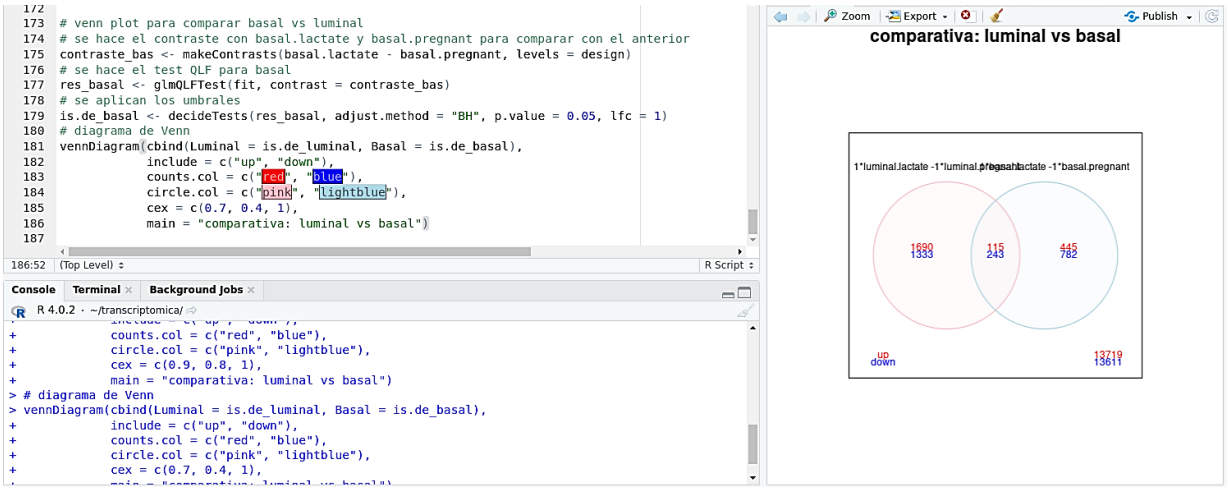
Console Terminal Background Jobs

R 4.0.2 · ~/transcriptomica/

```
+   geom_point(size = 0.2) +
+   scale_color_manual(values = c("NO" = "grey", "up" = "red", "down" = "blue")) +
+   geom_text(data = genes_top3, aes(label = rownames(genes_top3)),
+             vjust = -1, color = "black", show.legend = FALSE) +
+   labs(title = "luminal lactate vs pregnant",
+        x = "logFC (Cambio)", y = "-log10 FDR")
>
```



Captura de pantalla 14: se realiza el volcano plot para contestar al segundo apartado de la pregunta, y se etiquetan los 3 genes con mayor valor absoluto de logFC. Hacia la derecha (rojo) se representan los genes que han aumentado su producción; hacia la izquierda (azul) se representan los genes que se han reprimido, así conocemos su ENTREZID y su expresión (“up” o “down” -regulated).



Captura de pantalla 15: se realiza un Venn diagram para comparar el estudio que se hizo en clase de basal.lactate vs basal.pregnant y el que se hizo para este ejercicio, de luminal.lactate vs luminal.pregnant, para ver qué coincidencias y diferencias hay entre ambos estudios. Se tienen en cuenta los puntos de corte designados.

- ¿Cuántos genes diferencialmente expresados (DEG) obtienes, aplicando un punto de corte de FDR <= 0.05 y un valor absoluto de logFC >= 1?
    - Tras aplicar la función decideTests con los puntos de corte establecidos en el enunciado, se identificaron **un total de 3381 genes diferencialmente expresados** en las células luminales en la transición de pregnant → lactate. Estos genes se clasifican en:
        - **1805 son genes "up" (sobreexpresados).**
        - **1576 son genes "down" (reprimidos).**

- Dibuja un Volcano plot y etiqueta los 3 genes con mayor valor absoluto de logFC. ¿Cuáles son y que valor representan?

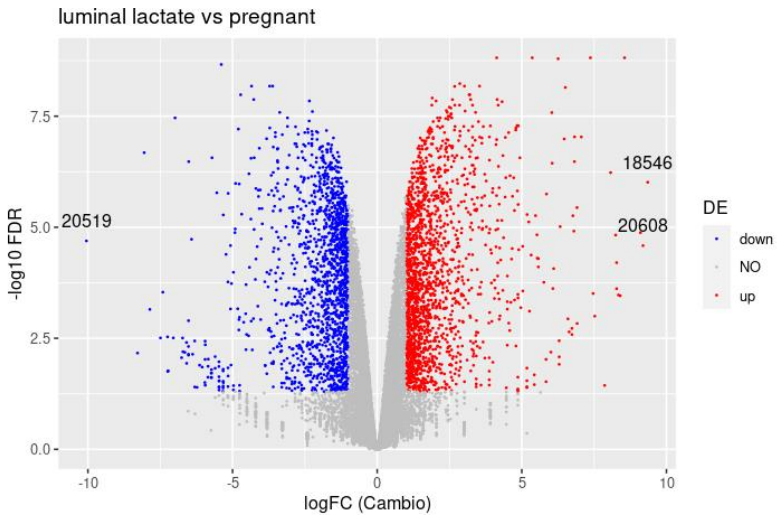


Gráfico 8: realización del *volcano plot*. En el eje X, siguiendo la fórmula que se estableció en el código de "*lactate – pregnant",* todo lo que esté a la derecha del cero corresponde a los genes de la lactancia (rojo), y todo lo que esté a la izquierda del cero corresponde a los genes de la gestación (azul). En el cero están los genes que no presentan expresión diferencial. Por otro lado, en el eje Y, el *-log10 FDR* indica que cuanto más alto esté un punto, más significancia estadística posee ("más fiable es").

- Tal y como se puede observar en las etiquetas del Gráfico 8, los 3 genes que sufren un mayor salto de expresión son:
  - 20519 → represión metabólica durante la lactancia.
  - 18546 → sobreexpresado en la lactancia.
  - 20608 → sobreexpresado en la lactancia.

  Tras buscar dichos genes en una base de datos, estos corresponden a:

ENTREZID[4]	SYMBOL	Estado en Lactancia	Función biológica en la glándula mamaria[5]
18546	*Pcp4*	**Sobreexpresado**	Regulador de calcio en el metabolismo de la leche
20608	*Sstr4*	**Sobreexpresado**	Receptor de somatostatina: detiene el crecimiento glandular postparto para gastar más recursos en la producción de leche
20519	*Slc22a3*	**Reprimido** (función durante la GESTACIÓN)	Transportador de membrana: se apaga para actuar como barrera física entre la sangre materna y la leche, impidiendo que toxinas, o metabolitos nocivos pasen a las crías durante la gestación

- ¿Cuántos genes únicos y compartidos (diferencia entre sobreexpresados e infraexpresados) puedes encontrar entre esta comparación y aquella que realizamos en clase entre *basal.lactate vs basal.pregnant*?. Para ello realiza un diagrama de Venn o un Upset plot donde muestres los resultados obtenidos. Recuerda emplear los datos obtenidos tras aplicar los puntos de corte especificados en el punto 1 de esta pregunta.

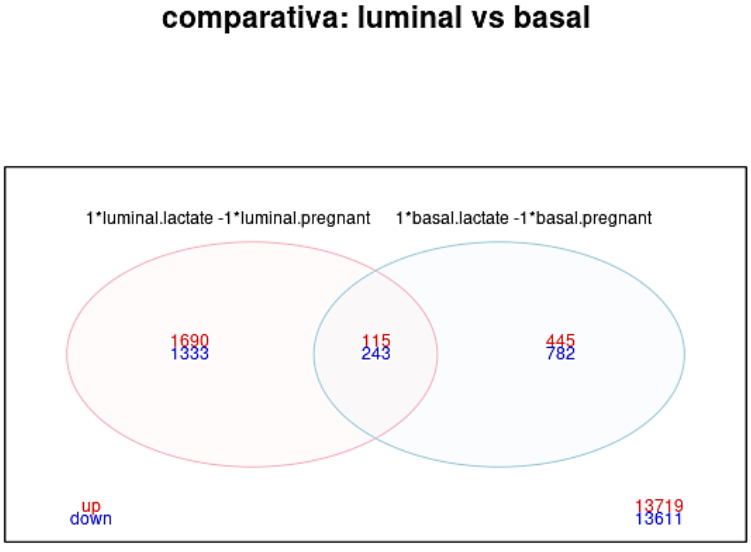
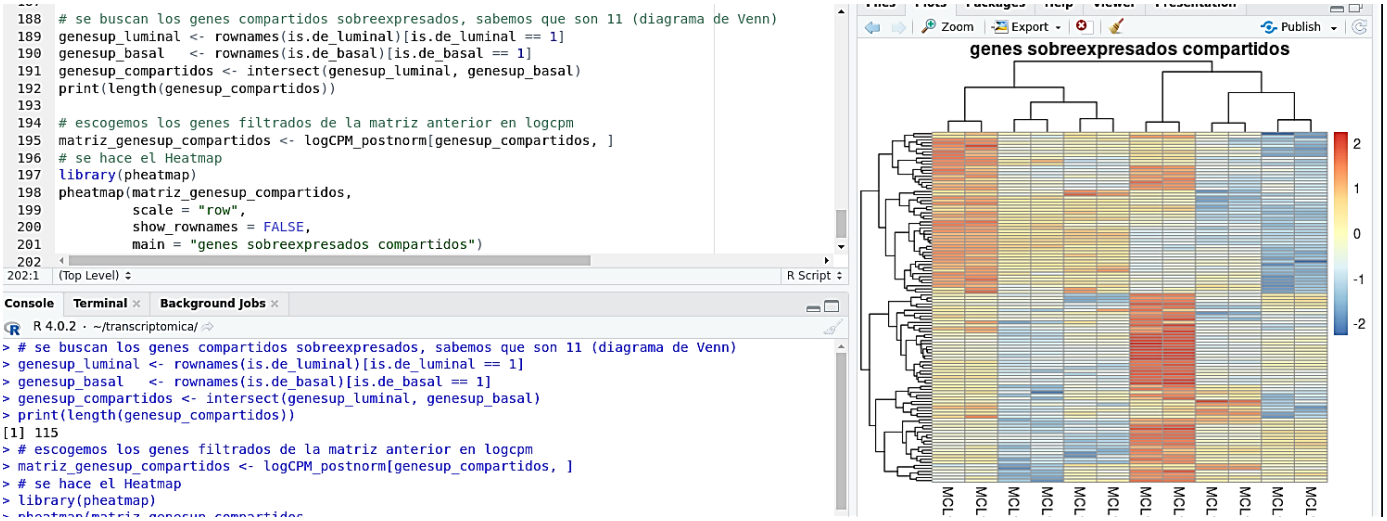


Gráfico 9: diagrama de Venn entre los linajes celulares basal vs luminal para valorar la expresión de genes compartidos y diferentes entre ambos estudios.

[4] https://www.syngoportal.org/convert
[5] https://www.ncbi.nlm.nih.gov/gene/

- Para comprender si el impacto de la lactancia es generalizado o específico de cada tipo celular, se realizó un diagrama de Venn (Gráfico 9) comparando los DEGs de basal.lactate vs basal.pregnant. Como se observa en la intersección del diagrama, **115 genes se sobreexpresan de forma simultánea en ambos linajes celulares**, y **243 genes se reprimen en ambos**. Esto demuestra que la lactancia realiza una activación de genes por igual en toda la glándula mamaria, sino que induce la expresión de genes especializados durante la gestación dependiendo de si la célula es basal o luminal.

P6. Emplea la matriz de conteos completa creada en la pregunta P3 (en logcpm) (1,5 pts).



Captura de pantalla 16: se filtra la matriz realizada en la P3, sabiendo según el diagrama de Venn anterior que son 115 genes los que se comparten entre ambos linajes celulares y están sobreexpresados ("up"). Se realiza el *Heatmap* con *pheatmap* utilizando dichos genes para completar el ejercicio.

- Filtra la matriz completa tomando únicamente los **genes compartidos** entre *basal* y *luminal* que se estén sobreexpresados en ambos. ¿Cuántos genes obtienes?

  - Al filtrar la tabla de resultados obtenemos un total de **115 genes compartidos *sobreexpresados en ambos***. Este resultado concuerda con el que vimos anteriormente en el Diagrama de Venn (Grafico 9).

- Genera un *heatmap* empleando la función *pheatmap* y comenta: ¿Cómo se organizan las muestras?
    - Analizando el heatmap (Gráfico 10) y observando los resultados analíticos del dendrograma[6] de muestras (arriba), se aprecia la primera gran división estructural: las muestras **se organizan principalmente en función de su linaje celular (célula basal vs. luminal) y no por su estado fisiológico (lactante vs. preñada)**. Además, según se aprecia por el dendrograma de genes (lateral izq.), aunque los 115 genes estén sobreexpresados en ambos tipos de células, **no lo hacen con la misma intensidad**. Desde un punto de vista biológico, este resultado demuestra que las diferencias intrínsecas de expresión entre linajes siguen siendo la principal fuente de variabilidad de los datos y por ello se organizan las muestras de esta manera.

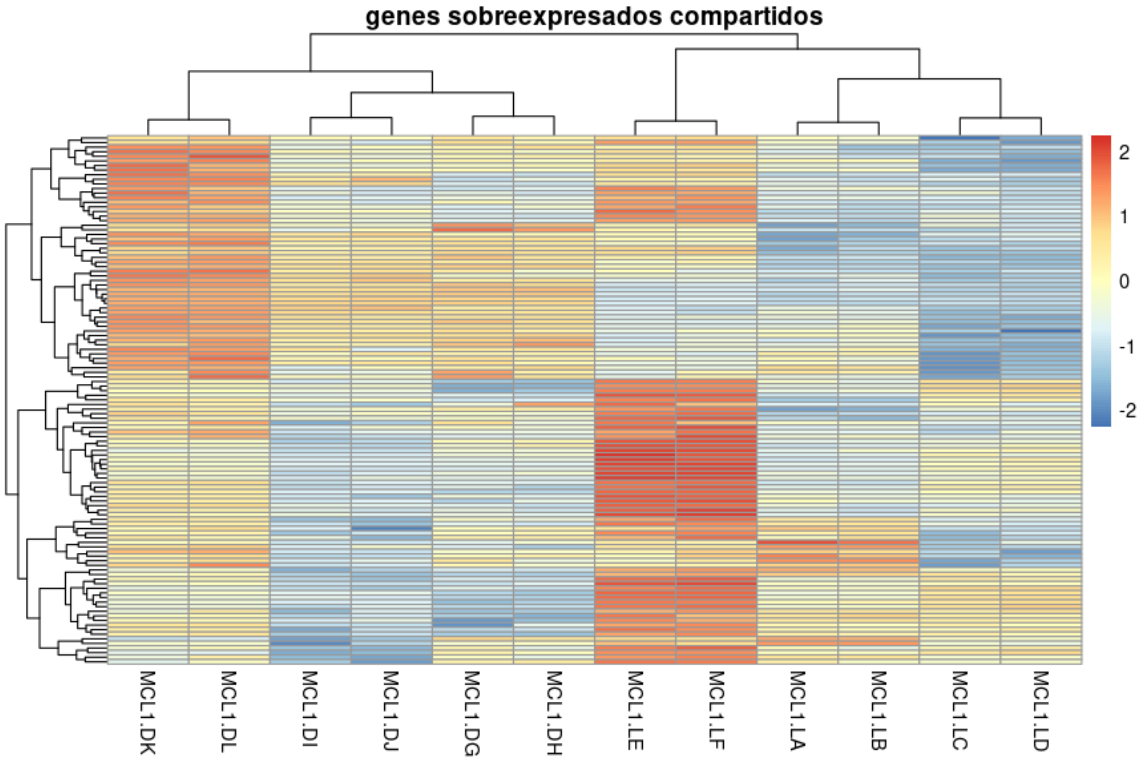


Gráfico 10: detalle del *heatmap* utilizando la función *pheatmap*

[6] NIH - Bioinformatics Training and Education Program. https://bioinformatics.ccr.cancer.gov/docs/data-visualization-with-r/Lesson5_intro_to_ggplot/

P7. Finalmente, con el grupo de genes obtenido en P6, realiza un análisis de enriquecimiento funcional indicando los 10 primeros resultados que reporta topGO en las categorías BP y MF. Comenta los resultados obtenidos y, si lo consideras necesario, apóyate de referencias bibliográficas (1 pts).

Para observar el papel biológico de los 115 genes diferencialmente sobreexpresados que se agruparon en la P6, se realizó un análisis de enriquecimiento utilizando la función *goana*() y *topGO*():

```
library(limma)
library(org.Mm.eg.db)
library(GO.db)
# los grupos definidos son el total de genes y el utilizado en el P6 de genes sobreexpresados
genes_total <- rownames(logCPM_postnorm)
# se hace el análisis de enriquecimiento usando la función "goana"
analisis_go <- goana(de = genesup_compartidos,
                     universe = genes_total,
                     species = "Mm")
# TOP 10 para Procesos Biológicos (BP)
top10_BP <- topGO(analisis_go, ontology = "BP", number = 10)
print(top10_BP)

# TOP 10 para Funciones Moleculares (MF)
top10_MF <- topGO(analisis_go, ontology = "MF", number = 10)
print(top10_MF)
```

```
220:1  (Top Level)
Console  Terminal  Background Jobs
R 4.0.2 · ~/transcriptomica/
> library(limma)
> library(org.Mm.eg.db)
> library(GO.db)
> # los grupos definidos son el total de genes y el utilizado en el P6 de genes sobreexpresados
> genes_total <- rownames(logCPM_postnorm)
> # se hace el análisis de enriquecimiento usando la función "goana"
> analisis_go <- goana(de = genesup_compartidos,
+                      universe = genes_total,
+                      species = "Mm")
> # TOP 10 para Procesos Biológicos (BP)
```

Captura de pantalla 17: detalle del código utilizado para el ejercicio en el que se muestran las librerías y los comandos empleados.

```
> top10_BP <- topGO(analisis_go, ontology = "BP", number = 10)
> print(top10_BP)
                                                Term Ont   N DE         P.DE
GO:0006695              cholesterol biosynthetic process  BP  41  7 4.485425e-11
GO:1902653        secondary alcohol biosynthetic process  BP  41  7 4.485425e-11
GO:0016126                  sterol biosynthetic process  BP  47  7 1.236784e-10
GO:0006694                steroid biosynthetic process  BP 116  8 2.915972e-09
GO:0008203               cholesterol metabolic process  BP 103  7 3.405109e-08
GO:0016125                    sterol metabolic process  BP 110  7 5.377421e-08
GO:1902652          secondary alcohol metabolic process  BP 112  7 6.092572e-08
GO:1901617 organic hydroxy compound biosynthetic process  BP 171  8 6.178695e-08
GO:0046165                alcohol biosynthetic process  BP 113  7 6.479290e-08
GO:1901615    organic hydroxy compound metabolic process  BP 381 10 2.757332e-07
> # TOP 10 para Funciones Moleculares (MF)
> top10_MF <- topGO(analisis_go, ontology = "MF", number = 10)
> print(top10_MF)
                                                                                Term Ont   N DE         P.DE
GO:0033721                                      aldehyde dehydrogenase (NADP+) activity  MF   3  2 2.984326e-05
GO:0030274                                                   LIM domain binding  MF   7  2 2.072032e-04
GO:0005229                  intracellular calcium activated chloride channel activity  MF  10  2 4.412966e-04
GO:0061778                                 intracellular chloride channel activity  MF  10  2 4.412966e-04
GO:0051428                                         peptide hormone receptor binding  MF  11  2 5.382633e-04
GO:0016765 transferase activity, transferring alkyl or aryl (other than methyl) groups  MF  50  3 5.383037e-04
GO:0008237                                                 metallopeptidase activity  MF 138  4 9.669714e-04
GO:0004659                                               prenyltransferase activity  MF  15  2 1.019247e-03
GO:0004029                                     aldehyde dehydrogenase (NAD+) activity  MF  16  2 1.162482e-03
GO:0004030                                  aldehyde dehydrogenase [NAD(P)+] activity  MF  17  2 1.314798e-03
>
```

Captura de pantalla 18: detalle de los resultados del top 10 de resultados obtenidos con *topGO* en las categorías BP y MF.

El análisis de enriquecimiento funcional aporta la información esperada acerca del proceso de la lactación y como afecta a la expresión de genes tanto en células luminales como basales, ya que aproximadamente

el 50% de los genes asociados con el transporte de solutos y la lipogénesis están sobreexpresados en la glándula mamaria durante la gestación y la lactación, muy por encima de otros tejidos, además de genes asociados en la conversión de glucosa y varios tipos de minerales[7]. La lactancia exige una reprogramación metabólica y secretora en las células de la glándula mamaria, tanto para las células luminales como para las basales[8], y los resultados del análisis realizado reflejan esta adaptación fisiológica:

- **Procesos Biológicos (BP):** la mayor parte de los resultados obtenidos aquí están relacionados con el metabolismo de los lípidos. La leche materna es una emulsión rica en lípidos y colesterol, elementos vitales para el desarrollo del sistema nervioso y las membranas celulares del feto, y durante la lactancia, la glándula mamaria (tanto en su componente luminal como basal) desvía gran parte de su energía hacia la lipogénesis y la síntesis de colesterol para enriquecer la leche[9]., por eso estos resultados concuerdan con la realidad biológica del proceso.
- **Funciones Moleculares (MF):** en esta categoría destacan procesos orientados al metabolismo mineral y hormonal de la producción de la leche, y procesos de protección ante los daños oxidativos.
    - En primer lugar, destaca la prominencia de la actividad aldehído deshidrogenasa (ALDH2) en el número 1, 9 y 10 del top 10 de funciones moleculares. La literatura reciente subraya el papel protector crítico de la ALDH2 durante la gestación y la lactancia, es de especial relevancia en procesos protectores maternos ante el daño oxidativo[10]. En este caso tiene sentido que exista un aumento de la actividad durante la lactación dado el masivo estrés oxidativo que genera la biosíntesis de lípidos para la leche materna, actuando así como un protector tisular endógeno. Además, conviene destacar también aquí el papel de las metalopeptidasas y otras proteínas funcionales que intervienen en esta clasificación, cuya actividad equilibrada es esencial para la salud de los tejidos.
    - Por otro lado, los genes metabólicos relacionados con la actividad de los canales de cloro activados por calcio son importantes porque la secreción de la leche es un proceso osmóticamente activo[11]; las células mamarias utilizan canales de iones para bombear fluidos hacia el lumen alveolar. De ahí que en el top 10 de genes, el puesto 3 y 4 sean genes relacionados con esta función.
    - Por último, la lactancia se sincroniza con la producción hormonal de la hembra, fundamentalmente la prolactina (estimula la síntesis de leche en las células luminales y es fundamental para el comportamiento materno[12]) y la oxitocina (provoca la contracción de las células basales para su eyección). La sobreexpresión de genes relacionados con estos receptores demuestra la hipersensibilización del tejido a estas señales endocrinas según los cambios en la gestación.

---

[7] Patel, O.V., Casey, T., Dover, H. et al. Homeorhetic adaptation to lactation: comparative transcriptome analysis of mammary, liver, and adipose tissue during the transition from pregnancy to lactation in rats. Funct Integr Genomics 11, 193–202 (2011). 10.1007/s10142-010-0193-0

[8,9] Jiang H, Xu X, Song X, Liu Q, Cui K, Li H, et al. Revealing gene expression links between milk fat globules and mammary glands in rodents via transcriptomics. Frontiers in Veterinary Science (2025). https://pmc.ncbi.nlm.nih.gov/articles/PMC12106365/

[10] Daniel Muñoz-Mayorga, Adriana Tovar, Mauricio Díaz-Muñoz, Teresa Morales. Lactation attenuates pro-oxidant reactions in the maternal brain. Molecular and Cellular Endocrinology, Volume 565 (2023) https://doi.org/10.1016/j.mce.2023.111888.

[11] Laleh Ardeshirpour, Pamela Dann, Martin Pollak, John Wysolmerski, Joshua VanHouten. The calcium-sensing receptor regulates PTHrP production and calcium transport in the lactating mammary gland. Bone, Volume 38, Issue 6 (2006), https://doi.org/10.1016/j.bone.2005.11.009

[12] Salais-López, H., Lanuza, E., Agustín-Pavón, C. et al. Tuning the brain for motherhood: prolactin-like central signalling in virgin, pregnant, and lactating female mice. Brain Struct Funct 222, 895–921 (2017). https://doi.org/10.1007/s00429-016-1254-5